



UNIDAD DE MAESTRIAS Y POSGRADOS EN ECONOMIA

Machine Learning aplicado a duración de precios

Un análisis en Montevideo para el período Enero 2021 – Junio 2024

Por

Paolo Pinotti

Martín Rey

Trabajo final de carrera presentado para optar al título de
Maestría en Ciencia de Datos

Tutores

Cecilia Regueira

Federico Veneri

Montevideo, Uruguay
2025

UNIVERSIDAD DE MONTEVIDEO
Unidad de Maestrías y Postgrados en Economía

Paolo Pinotti & Martín Rey

MACHINE LEARNING APLICADO A DURACIÓN DE PRECIOS
UN ANALISIS DE LA DURACIÓN DE PRECIOS EN MONTEVIDEO PARA EL PERIODO ENERO
2021 – JUNIO 2024

Tutores: Cecilia Regueira y Federico Veneri

TFC presentado para aspirar al título de Magister en Ciencia de Datos

Juicio del Tribunal:

Recomendación para su publicación en el Repositorio de la UM:

.....
.....
.....
.....
.....

Presidente:

(Firma) (Aclaración)

Secretario:

(Firma) (Aclaración)

Vocal:

(Firma) (Aclaración)

Montevideo, de de 2025

Descargo de responsabilidad

Los autores de este trabajo final de carrera declaran que son los únicos responsables de su contenido, y en particular de las opiniones expresadas en él, las que no necesariamente son compartidas por la Universidad de Montevideo; asimismo, declaran que no se infringe ningún derecho de terceros, ya sea de propiedad intelectual, industrial o cualquier otro. En consecuencia, son los únicos responsables y de manera exclusiva pueden asumir eventuales reclamaciones de terceros (personas físicas o jurídicas) que refieran a la autoría de la obra y a otros aspectos vinculados a ésta, incluido el reclamo por plagio.

Agradecimientos

Quisiéramos agradecer a la Universidad de Montevideo (UM) y a la Unidad de Maestría y Postgrados en Economía (UMPE) por la formación brindada durante los últimos dos años; especialmente a los profesores y personal de soporte de la Maestría en Ciencia de Datos.

A nuestros tutores Cecilia Regueira y Federico Veneri por su asistencia y guía continua, sus constantes aportes de conocimiento fueron factor clave para potenciar nuestro esfuerzo.

Por último, queremos agradecer a nuestros familiares y amigos, especialmente, a ‘Vale’, ‘Juli’, ‘Tomi’, Mónica, Ramiro, Flora y Emiliano, por su incondicional apoyo durante el último año. No existe mayor premio que tenerlos en nuestras vidas.

Paolo Pinotti & Martín Rey

Tabla de contenido

Lista de tablas	vii
Lista de figuras.....	viii
Lista de abreviaturas y siglas	ix
Resumen.....	x
Palabras Clave.....	x
Introducción	1
Antecedentes	2
Estudios Empíricos sobre Dinámica de Precios	2
Aplicaciones de Machine Learning en Precios	6
Modelos Survival en la Predicción de Eventos.....	8
Metodología	10
Algoritmos utilizados	10
Arboles de Regresión.	11
Random Forest.....	12
XGBoost (Extreme Gradient Boosting)	12
CatBoost (Categorical Boosting).....	13
LightGBM (Light Gradient Boosting Machine).....	14
Cox Proportional Hazards	15
Random Survival Forest (RSF)	16
Marco Teórico para la construcción de las Bases de Datos	16
Estrategias de validación.....	18
Datos	20
Fuente de información.....	20
Origen, Relevamiento y Alcance Temporal	20
Transformación y limpieza de los datos.	21
Análisis Exploratorio	27
Duración	27
Rubro y Categoría.....	32
Cadena y Tipo de Establecimiento	34
Variables Cronológicas: Mes, Día del Mes y Día de la Semana	35

Municipios	38
Precios: Promoción y Variación de Precios	39
Resultados	43
Conclusiones	49
Apéndice	51
Apéndice A: Classification and Regression Tree (CART).....	51
Apéndice B: Boosting.....	52
Apéndice C: Cox Proportional Hazards	53
Anexos	54
Anexo 1: Definición de la variable: Tipo de Establecimiento.	54
Anexo 2: Productos considerados	56
Anexo 3: Descripción de variables definidas.....	59
Anexo 4: Complemento de Análisis Exploratorio	62
Anexo 5: Resultados modelización con Machine Learning.....	76
Anexo 6: Resultados modelización con Survival Machine Learning	84
Anexo 7: Base de Datos y Código Desarrollado.....	86
Bibliografía	87

Lista de tablas

Tabla 1: Estadísticos generales de la variable <i>Duración</i>	28
Tabla 2: Distribución por <i>Rubro</i>	32
Tabla 3: Distribución por <i>Día de la Semana</i>	36
Tabla 4: Estadísticos de la variable <i>Duración</i> discriminando por <i>Promoción</i>	39
Tabla 5: Distribución por incrementos y reducciones de <i>Precio</i>	40
Tabla 6: Mejores Resultados modelización General y específica por <i>Rubro</i> (<i>Machine Learning</i>)	44
Tabla 7: Mejores Resultados modelización <i>General</i> y específica por <i>Rubro</i> (<i>Survival Machine Learning</i>)	45
Tabla 8: Relevancia de predictores en la modelización por <i>Rubro</i> (<i>Machine Learning</i>)	48
Tabla 9: Productos considerados	56
Tabla 10: Variables definidas	59
Tabla 11: Distribución por <i>Cadena</i>	66
Tabla 12: Distribución por <i>Tipo de Establecimiento</i>	68
Tabla 13: Distribución por <i>Municipio</i>	74
Tabla 14: Resultados modelización General (<i>Machine Learning</i>)	76
Tabla 15: Comparativa de resultados <i>Train</i> vs <i>Test</i> modelización General (<i>Machine Learning</i>)	78
Tabla 16: Resultados modelización <i>Machine Learning</i> (<i>Rubro: Alimentos</i>)	79
Tabla 17: Resultados modelización <i>Machine Learning</i> (<i>Rubro: Bebidas con Alcohol</i>)	80
Tabla 18: Resultados modelización <i>Machine Learning</i> (<i>Rubro: Bebidas sin Alcohol</i>)	81
Tabla 19: Resultados modelización <i>Machine Learning</i> (<i>Rubro: Cuidado Personal</i>)	82
Tabla 20: Resultados modelización <i>Machine Learning</i> (<i>Rubro: Limpieza</i>)	83
Tabla 21: Resultados modelización General (<i>Survival Machine Learning</i>)	84
Tabla 22: Comparativa de resultados <i>Train</i> vs <i>Test</i> modelización General (<i>Survival Machine Learning</i>)	84
Tabla 23: Resultados modelización <i>Survival Machine Learning</i> por <i>Rubro</i>	85

Lista de figuras

Figura 1: Ejemplo ilustrativo de una serie de <i>Price Spell</i> para un par establecimiento-producto determinado	25
Figura 2: Distribución de <i>Duración</i> de los <i>spells</i>	30
Figura 3: Evolución general de la duración promedio de los <i>spells</i> (<i>enero 2021 – junio 2024</i>)	31
Figura 4: Distribución de las duraciones de los <i>spells</i> por <i>Categoría</i>	34
Figura 5: Cantidad de <i>spells</i> por <i>Día del Mes</i>	37
Figura 6: Cantidad de <i>spells</i> y duración media por <i>Mes</i>	38
Figura 7: Relevancia de predictores en el modelo <i>XGBoost</i> Optimizado del modelo General	47
Figura 8: Evolución por <i>Rubro</i> de la duración promedio de los <i>spells</i> (<i>enero 2021 – junio 2024</i>)	62
Figura 9: Distribución de <i>spells</i> por <i>Categoría</i>	65
Figura 10: Mapa de Calor: Relación entre <i>Duración</i> , <i>Categoría</i> y <i>Tipo de Establecimiento</i>	69
Figura 11: Media de <i>Duración</i> vs Media <i>Var_Precio_%</i> (Incrementos) por <i>Rubro</i>	75
Figura 12: Media de <i>Duración</i> vs Media <i>Var_Precio_%</i> (Reducciones) por <i>Rubro</i>	75

Lista de abreviaturas y siglas

ARIMA - Modelo Autorregresivo Integrado de Media Móvil (<i>en inglés: AutoRegressive Integrated Moving Average</i>)	LGD - Pérdida en Caso de Incumplimiento (<i>en inglés: Loss Given Default</i>)
BCU - Banco Central del Uruguay	LightGBM - Máquina de Impulso de Gradiente Ligera (<i>en inglés: Light Gradient Boosting Machine</i>)
BLS - Oficina de Estadísticas Laborales (<i>en inglés: Bureau of Labor Statistics</i>)	LSTM - Memoria a Largo y Corto Plazo (<i>en inglés: Long Short-Term Memory</i>)
CART - Árbol de Clasificación y Regresión (<i>en inglés: Classification and Regression Tree</i>)	MAE - Error Absoluto Medio (<i>en inglés: Mean Absolute Error</i>)
C-Index - Índice de Concordancia (<i>en inglés: Concordance Index</i>)	MEF - Ministerio de Economía y Finanzas
CV - Coeficiente de Variación	MSE - Error Cuadrático Medio (<i>en inglés: Mean Squared Error</i>)
EFB - Agrupamiento Exclusivo de Características (<i>en inglés: Exclusive Feature Bundling</i>)	Q25% - Primer Cuartil Estadístico
GOSS - Muestreo Unilateral Basado en el Gradiente (<i>en inglés: Gradient-based One-Side Sampling</i>)	Q50% - Mediana Estadística
INE - Instituto Nacional de Estadística	Q75% - Tercer Cuartil Estadístico
IPC - Índice de Precios al Consumo	RI - Rango Intercuartílico
KNN - K Vecinos Más Cercanos (<i>en inglés: K-Nearest Neighbors</i>)	RMSE - Raíz del Error Cuadrático Medio (<i>en inglés: Root Mean Squared Error</i>)
LASSO - Operador de Selección y Contracción Absoluta Mínima (<i>en inglés: Least Absolute Shrinkage and Selection Operator</i>)	RSF - Survival Random Forest
	SDP - State Dependent Pricing
	SGB - Survival Gradient Boosting
	SIPC - Sistema de Información de Precios al Consumidor
	TDP - Time Dependent Pricing
	XGBoost - Impulso Extremo del Gradiente (<i>en inglés: eXtreme Gradient Boosting</i>)

Resumen

Comprender la frecuencia con la que cambian los precios en el comercio minorista resulta esencial para analizar la formación de precios, el comportamiento de los consumidores y el diseño de políticas públicas. El presente trabajo examina los factores que inciden en la duración de los precios, mediante el uso de modelos de aprendizaje automático y análisis de supervivencia. A partir de series temporales diarias de 150 productos en 289 supermercados de Montevideo, entre enero de 2021 y junio de 2024, se entrenaron modelos supervisados tradicionales (*Decision Tree*, *Extra Trees*, *Random Forest*, *XGBoost*, *CatBoost* y *LightGBM*) y modelos de supervivencia (*Cox Proportional Hazards* y *Random Survival Forest* (RSF)). Como resultado de la comparación entre ambos enfoques, *XGBoost* obtuvo el mejor desempeño general (MAE = 8.99 días), mientras que RSF presentó el mayor C-Index (0.729) entre los modelos de supervivencia. Un análisis desagregado por rubro evidenció la existencia de heterogeneidades en los factores que explican la duración de los precios entre productos, hecho que sugiere la no existencia de un único modelo o conjunto de variables explicativas óptimo.

Palabras Clave

Precios retail en Uruguay; Fijación de precios; Duración de precios; Price spell; Machine Learning; Análisis de supervivencia

Abstract

Understanding the frequency at which prices change in the retail sector is essential for analyzing price formation, consumer behavior, and the design of public policies. This study examines the factors that influence price duration using machine learning models and survival analysis techniques. Based on daily time series data for 150 products across 289 supermarkets in Montevideo, between January 2021 and June 2024, both traditional supervised models (*Decision Tree*, *Extra Trees*, *Random Forest*, *XGBoost*, *CatBoost*, and *LightGBM*) and survival models (*Cox Proportional Hazards* and *Random Survival Forest* (RSF)) were trained. Among the models compared, *XGBoost* achieved the best overall performance (MAE = 8.99 days), while RSF yielded the highest C-Index (0.729) among the survival models. A disaggregated analysis by product heading revealed significant heterogeneity in the factors explaining price duration, suggesting that there is no single optimal model or universal set of explanatory variables.

Keywords:

Retail prices in Uruguay; Price setting; Price duration; Price spell; Machine Learning; Survival analysis

Introducción

Las estrategias de fijación de precios de supermercados y retailers tiene un efecto directo sobre el bienestar de los consumidores y agregados macroeconómicos. La periodicidad con la que los establecimientos ajustan sus precios incide tanto en la inflación como en las expectativas de compra de los consumidores, siendo un tema de relevancia para la literatura económica. Este trabajo busca contribuir a la literatura empírica analizando, tanto los factores que influyen en las estrategias de fijación de precios en los supermercados uruguayos, como en la precisión con la que estos realizan dichos ajustes.

Se crearon series temporales de precios correspondientes a 150 productos, que representan el 14.75% de las categorías definidas por el INE¹ para el cálculo del IPC ² ³, en 289 establecimientos de Montevideo, Uruguay, durante el período comprendido entre enero de 2021 y junio de 2024. El objetivo fue predecir la frecuencia con la cual acontecen las modificaciones de precio a través de la variable *Duración*. Se implementaron dos enfoques de aprendizaje supervisado: árboles de regresión (a través de los modelos *Decision Tree*, *Extra Trees*, *Random Forest*, *XGBoost*, *CatBoost* y *LightGBM*) y análisis de supervivencia (a través de los modelos *Cox Proportional Hazards* y *Survival Random Forest (RSF)*).

La capacidad predictiva de los modelos surgidos de estos dos enfoques fue probada mediante una estrategia de validación cruzada para el total de la muestra y luego por separado en cada rubro. Los resultados sugieren que el algoritmo *XGBoost* presenta los mejores resultados, con un error absoluto medio de predicción (MAE) de 8.99 días.

El documento se estructura de la siguiente manera: el capítulo 2 presenta los antecedentes. El capítulo 3, un resumen de la metodología empleada. El capítulo 4, los datos utilizados. El capítulo 5, los principales resultados de ambas estrategias. Por último, el capítulo 6 contiene los comentarios finales y una síntesis del trabajo realizado.

¹ Instituto Nacional de Estadística (INE).

² Índice de Precios al consumo (IPC).

³ Más específicamente, el 27.69% de las divisiones 01, 02, 05 y 13 de dicho índice, siguiendo su reformulación adoptada en el año 2022 (Instituto Nacional de Estadística [INE], 2022).

Antecedentes

Estudios Empíricos sobre Dinámica de Precios

Diversos autores han contribuido a la literatura económica sobre las estrategias de fijación de precios. Nuestra revisión se centra en estudios empíricos, que buscan identificar qué factores inciden en las decisiones de cambios de precios.

Los modelos comportamentales de precios pueden enmarcarse en dos grandes enfoques: *Time Dependent Pricing* (TDP) y *State Dependent Pricing* (SDP). El enfoque Time Dependent plantea que la probabilidad en la modificación de los precios de una empresa es una función dependiente del tiempo y de carácter exógeno (Walsh, 2017). El enfoque State Dependent establece que la variación de precios de una empresa está condicionada al estado general de la economía, es de carácter endógeno y tienden a ajustarse por encima del óptimo (Dotsey et al., 1999).

Para identificar que mecanismos prevalecen, los estudios empíricos centran su atención en el concepto de *Price Spell*. (Aucremanne & Dhyne, 2004) en su estudio sobre las rigideces de precios, definen *Price Spell* como un intervalo de tiempo en el que el precio de un producto permanece sin variaciones en un establecimiento determinado. Cuando acontece un cambio de precio se da por finalizado el *spell* e inicia el siguiente. El estudio de su duración, frecuencia de los cambios y magnitud es parte del análisis de la estrategia de fijación de precios y la base del estudio de los mecanismos de ajuste.

En el plano internacional, (Klenow & Kryvtsov, 2008) utilizando microdatos recopilados por la Oficina de Estadísticas Laborales (BLS) de Estados Unidos para el Índice de Precios al Consumidor (IPC) entre 1988 y 2004, hallaron que los cambios de precios son frecuentes (cada cuatro o siete meses dependiendo de si son considerados o no precios en promoción) y significativos en cuanto a su magnitud (10% en promedio); aunque ambas características de los cambios, tamaño y tiempo, son heterogéneas entre productos. Asimismo, los autores

concluyen que el tamaño y la probabilidad de los cambios de precio no guardan correlación con el último cambio de precio registrado.

Continuando esta línea de investigación, (Nakamura & Steinsson, 2008), amplían la información utilizada por (Klenow & Kryvtsov, 2008) —añadiendo a los precios al consumidor (o precios de góndola) los precios reportados por productores, en el mismo horizonte temporal. (Nakamura & Steinsson, 2008) establecieron que la frecuencia media de cambio de precios en productos en promoción es el doble que la de productos que no lo están. A su vez, identificaron que casi un tercio de las modificaciones de precio de productos no en promoción corresponden a disminuciones de precio, que los aumentos de precio mantienen correlación directa con la inflación mientras que las disminuciones no lo hacen, y que la modificación generalizada de precios es un fenómeno estacional que acontece mayormente en el primer trimestre del año.

(Vermeulen et al., 2012) analizaron el comportamiento de precios en seis países de la zona euro (Alemania, Bélgica, España, Francia, Italia y Portugal) entre los años 1991 y 2005, con distintos horizontes temporales según el país.⁴ Los autores encuentran que los cambios de precios son poco frecuentes (sólo el 21% de ellos cambian en el transcurso de un mes), que el 55% de las modificaciones de precios son al alza y que factores como la estructura de costos, el nivel de competencia del mercado, la estacionalidad, la inflación y la atraktividad de los precios fijados tienen efecto en la evolución y tamaño de la modificación en precios.

(Ellis, 2009) realiza un estudio similar a los anteriores focalizado en Gran Bretaña, encontrando que un cuarto de los precios sufre alteraciones semanalmente y, si se desconsidera ajustes temporales por factores como promociones, dicha magnitud asciende al 40%. A su vez, destaca comportamientos inversos a los vistos por (Nakamura & Steinsson, 2008) en Estados Unidos, al inferir que las modificaciones de precio no obedecen un patrón estacional y, similar a (Klenow & Kryvtsov, 2008), que no existe una correlación entre la longevidad de un precio y su posterior magnitud de cambio. Uno de los principales aportes

⁴ Alemania (enero 1997- diciembre 2002), Bélgica (enero 2001 – enero 2005), España (noviembre 1991 – febrero 1999), Francia (enero 1994 – junio 2005), Italia (enero 1997, diciembre 2002) y Portugal (enero 1995 – diciembre 2000).

del anterior trabajo es la óptica semanal adoptada para la presentación de los datos, demostrando que escalas mensuales tienden a sobreestimar tanto la cantidad como la velocidad en el ajuste de los precios.

Dentro de los países latinoamericanos, (Cavallo, 2015) por medio de series temporales diarias de precios en supermercados, obtenidas mediante técnicas de scraping para Argentina, Brasil, Chile, Colombia y Estados Unidos entre octubre del 2007 y agosto del 2010, estima que la durabilidad media de los precios se encuentra entre los 38 días (caso Brasil) y 75 días (caso Chile). A su vez, concluye que la frecuencia relativa entre la cantidad de aumentos y reducciones de precios es la única variable relevante para estimar el nivel de crecimiento de precios de las economías analizadas.

En Brasil, (Correa et al., 2016) cuantificaron que la duración promedio de los precios es de 3.3 meses, con un promedio del 20% de empresas que cambian sus precios mensualmente. Estas magnitudes se encuentran por encima del promedio de los países Euro, Gran Bretaña y Estados Unidos según señalan los autores. Asimismo, hallaron que la inflación y los costos de bienes intermedios (costos asociados a la producción de bienes) son los mayores condicionantes en las alteraciones de precios transversalmente entre los distintos sectores de la economía (comercial, manufacturación y servicios).

En México, (Kochen, 2016) encuentra que la duración promedio de los precios incluyendo promociones es de 2.7 meses, mientras que si se excluyen, la media aumenta a 3 meses. A su vez, identifica que el 17.4% de la totalidad de los precios (13.4% si se excluyen promociones) se modifican quincenalmente⁵, aunque se presentan heterogeneidades significativas entre categorías de productos. Además, estimó que el 60.4% de las modificaciones de precio constituyen aumentos, siendo el promedio de dichas variaciones superior al 10% con una distribución bimodal, aunando grandes modificaciones de precios con otras cercanas al 0%.

(Peña & Prades, 2021), obtienen mediante scraping precios de productos comercializados en línea por los dos principales retailers de Chile, la principal cadena farmacéutica y los

⁵ Cohorte temporal adoptada en el estudio de referencia.

principales concesionarios automotrices de dicho país, entre julio de 2019 y noviembre de 2020. Las autoras estiman que la duración promedio de los precios es de 2.2 meses, cifra que varía significativamente según la categoría de productos y se encuentra afectada por eventos como la pandemia de COVID-19 y conflictos sociales acontecidos en el país. Además, se observó que los cambios de precios en Chile tienden a ser de baja magnitud, predominando los incrementos por sobre las reducciones.

En Uruguay (Borraz & Zipitría, 2013) utilizando datos diarios sobre la evolución de precios en supermercados, estiman que para el período abril 2007 - diciembre 2010 la duración media de los precios fue de 2.5 meses. A su vez, identifican que no existe patrón estacional en el ajuste de precios, aunque es usual que dichas modificaciones acontezcan entre los días 1 y 9 de cada mes, y que la sincronización de precios entre establecimientos es alta. Este comportamiento se encuentra en línea con los modelos de fijación de precios dependientes del estado (*State Dependent Pricing* (SDP)).

Algunos años más tarde (Zipitría & Rius, 2016) en un estudio sobre la estructura competitiva de los mercados de bienes y servicios uruguayos, logran estimar que casi un tercio de la canasta del IPC puede llegar a estar influida por comportamientos anticompetitivos en bienes o establecimientos específicos, factor que puede influir en la inflación general de los precios. No obstante, a pesar de que logran identificarse cadenas con tendencia a ajustar precios por encima del nivel inflacionario, se concluye que no existen cadenas con poder de mercado suficiente para modelar la trayectoria generalizada de los precios.

Más cercano en el tiempo, (Regueira, 2020) en un horizonte temporal más amplio (enero 2011 - diciembre 2019) y utilizando series mensuales, estima que la duración promedio de los precios entre los principales retailers de Uruguay es de 3.99 meses. Similar a lo que acontece en otros países, la autora estima que los incrementos de precios son más frecuentes que las reducciones. Uno de los hallazgos más relevantes del mencionado trabajo es la detección de una correlación inversa entre la frecuencia en los cambios de precio y su tamaño de cambio; asociación que no siempre está presente en estudios similares para otros países (Ellis, 2009).

En síntesis, los estudios sobre fijación de precios relevados muestran una notable heterogeneidad en sus resultados, con diferencias significativas entre regiones y períodos. En territorios como Estados Unidos y otros países de la zona Euro, las modificaciones de precio suelen ser menos frecuentes y de menor envergadura, contrario a lo visto en países latinoamericanos, donde la sostenibilidad de precios es menor y su variabilidad mayor. Factores como la inflación, la estacionalidad y la prevalencia de promociones, entre otros, muestran ser determinantes en las estrategias de fijación de precio a nivel global.

Aplicaciones de Machine Learning en Precios

En las últimas décadas la utilización de técnicas de aprendizaje automático como *Machine Learning* han potenciado trabajos de investigación de diversa índole, desde ámbitos como la medicina y los estudios sociales hasta ciencias más duras, tales como la ingeniería computacional y las finanzas.

Estudios sobre el mercado inmobiliario en Nueva York (Calainho et al., 2024) y Hong Kong (Ho et al., 2021) destacan cómo ciertos modelos de *Machine Learning* pueden arrojar mejores resultados predictivos que modelos tradicionales. Similarmente, otros investigadores han utilizado estas técnicas con múltiples fines, como la predicción del precio de almacenamiento de datos en la nube (Veena et al., 2017), precios de productos comercializados en plataformas de e-commerce (Bodoh-Creed et al., 2018) o la estimación de la demanda energética (Alexandre et al., 2020).

No obstante, a pesar de la expansión generalizada de su uso, la literatura sobre la aplicación de *Machine Learning* en comportamiento de precios es escasa, concentrándose fundamentalmente en la evolución y predicción de la inflación a nivel agregado.

En Estados Unidos (Medeiros et al., 2021), utilizando variables macroeconómicas mensuales para los períodos de 1990-99 y 2000-15 concluyen que el modelo *Random Forest* logra captar

de mejor manera las volatilidades en la evolución de los precios, por encima de modelos econométricos clásicos como el *Random Walk* o el *Modelo Autorregresivo AR*.

En Costa Rica (Rodríguez-Vargas, 2020), utilizando datos macroeconómicos de cohorte mensual, contrasta la capacidad predictiva entre modelos econométricos tradicionales y de *Machine Learning* (*LSTM*, *KNN Univariado* y *Random Forest*). El autor plantea que estos últimos alcanzan mejores resultados predictivos, e incluso pueden mejorar su desempeño al combinarse.

Más recientemente, en Brasil (Araujo & Gaglianone, 2023) comparan cincuenta métodos de distinta naturaleza para pronóstico inflacionario (*Machine Learning*, modelos econométricos tradicionales y combinación de pronósticos) para múltiples horizontes temporales (de 1 a 18 meses); y concluyen que los modelos *Random Forest* y *XGBoost* presentan los menores errores cuadrático medio (MSE) en su predicción.

En Uruguay (Romero, 2021), utilizando como insumo las expectativas de inflación mensuales de unas quinientas empresas uruguayas entre los años 2009 y 2020, desarrolló modelos *Ridge*, *Lasso*, *Adaptive Lasso* y *Random Forest* de *Machine Learning* para evaluar sus respectivas capacidades predictivas. El autor concluye que todas las técnicas anteriormente citadas muestran una mejor performance tanto respecto a modelos econométricos tradicionales (*Modelo Autorregresivo* de orden 1 *AR(1)*, *Modelo autorregresivo integrado de media móvil (ARIMA)* y *Modelo RB*) como a las medianas de las expectativas inflacionarias de las empresas evaluadas y la métrica determinada por profesionales del Banco Central del Uruguay (BCU).

En nuestra revisión de la literatura, no se encontraron otros estudios que aplicaran metodologías de *Machine Learning* para el estudio de duración de precios en Uruguay.

Modelos Survival en la Predicción de Eventos

Los modelos tradicionales de *Machine Learning* supervisado suelen clasificarse en regresión o clasificación. Nuestro objeto de estudio es la duración de los precios, que, si bien puede estudiarse desde una óptica de regresión, considerando la duración como una variable continua, resulta también pertinente considerar un enfoque de supervivencia o *Survival*.

Los modelos *Survival* buscan estimar el tiempo que transcurre hasta la ocurrencia de un evento de interés. Su principal aporte radica en su capacidad para manejar datos censurados y predecir la ocurrencia del objeto estudiado, identificando patrones complejos y tendencias a lo largo del tiempo.

El campo donde estos modelos han tenido mayor aplicación es la medicina. Su uso en estudios clínicos ha facilitado la comparación entre medicamentos y tratamientos, optimizando su aplicación según las características de cada paciente y proyectando su evolución bajo dichos efectos.

En particular, el algoritmo de *Random Survival Forest* (RSF) ha demostrado aptitud en la predicción de resultados de supervivencia, especialmente en patologías oncológicas. (Rahman et al., 2021), (L.-W. Li et al., 2024), (Saha et al., 2024).

Un alto porcentaje de estudios financieros han utilizado la capacidad de los modelos *Survival Machine Learning* como instrumental para la estimación del riesgo crediticio; más precisamente en la clasificación crediticia de clientes y en su potencial riesgo de default. En esta línea (Wang et al., 2018) emplean un modelo ensamblado de *Random Forest* y *Survival Random Forest* (RSF) para la proyección de la probabilidad de default de clientes durante la concesión de un crédito. Otros ensayos como (Bai et al., 2022) y (Bone-Winkel & Reichenbach, 2024) emplean modelos *Survival Gradient Boosting* (SGB) en la asignación de la calidad crediticia para España-Estonia-Finlandia y Estados Unidos-China respectivamente. En todos los estudios mencionados la performance de los modelos *Survival*

obtuvo un mayor acierto predictivo que los modelos lineales de clasificación tradicionalmente utilizados en este ámbito.

Fuera del ámbito crediticio (Alanis et al., 2022), estudian los condicionantes que derivan en la declaración de bancarrota de empresas estadounidenses. En su investigación utilizan diversos modelos de *Machine Learning* y *Deep Learning* (*Lasso*, *Ridge*, *XGBoost*, *LightGBM*, *Random Forest*, *Survival Random Forest* (RSF) y redes neuronales) obteniendo el mejor desempeño en *Random Forest* y *Survival Random Forest* (RSF) en los casos donde se utilizan pocas variables, en contextos de crisis financiera y bajo la incorporación de variables cuantitativas derivadas de análisis de sentimientos.

Por último, un trabajo a mencionar es el de (van der Wal, 2024) quien, utilizando un historial de hipotecas estadounidenses de Freddie Mac, desarrolló un modelo *Random Survival Forest* (RSF) para estimar las pérdidas en caso de incumplimiento (LGD), obteniendo un alto poder de discriminación y calibración, superando incluso a modelos tradicionales de regresión y al modelo *Cox Proportional Hazards*.

En nuestra revisión no encontramos otros trabajos que hayan empleado este tipo de técnicas con series de precios de mercado, siendo este el primer trabajo que aborda la temática por esta vía.

Metodología

En este capítulo se explicitan los modelos utilizados para desarrollar el análisis predictivo sobre duración de precios, las definiciones asociadas a la creación de las bases de datos utilizadas y las estrategias de validación seguidas.

Los modelos fueron desarrollados mediante métodos de aprendizaje supervisado. En lo que sigue notaremos Y_i como la variable dependiente y X_i como las variables predictoras. En nuestro caso la variable dependiente es *Duración*, el tiempo durante el cual el precio permanece incambiado (hecho que denominamos *Price Spell*). A su vez, las variables predictoras son: la información asociada al tipo de bien (*Categoría* y *Promoción*), el lugar donde este se comercializa (*Cadena*, *Tipo de Establecimiento* y *Municipio*), el momento temporal en cual se da inicio a un nuevo precio (*Mes*, *Día del Mes* y *Día de Semana*) e información comparativa respecto al *spell* anterior (*Var Precio %* y *Lag DuracionI*) (Véase: Definición de Variables en [Anexo 3](#)).

Algoritmos utilizados

Se implementaron dos enfoques distintos de aprendizaje supervisado, uno basado en árboles de regresión y otro en análisis de supervivencia.

El primer enfoque está asociado a los métodos tradicionales de *Machine Learning* e incluye a los algoritmos: *Decision Tree*, *Extra Trees*, *Random Forest*, *XGBoost*, *CatBoost* y *LightGBM*. Estos métodos asumen que la variable dependiente es continua y no existen mecanismos de censura en los datos.

El segundo enfoque también considera métodos basados en árboles, pero incorpora el hecho de que la duración de los precios no es continua, sino que el tiempo es discreto y permite trabajar con datos censurados. Para este enfoque tomamos como referencia el *Survival Random Forest* (RSF). Dado que es un método relativamente reciente, lo comparamos con un modelo tradicional de *Proportional Hazards* o modelo de *Cox*.

A continuación, se presenta un breve resumen de los modelos implementados.

Arboles de Regresión.

Un árbol de regresión es un modelo basado en una estructura jerárquica, donde cada nodo representa una condición o prueba sobre las características de los datos (VanderPlas, 2016). Según se explica en *An Introduction to Statistical Learning* (James et al., 2023), la construcción de un árbol de decisión sigue un proceso conocido como *recursive binary splitting*, donde este se divide de manera sucesiva en nodos. En cada nodo, se selecciona la característica que mejor separa los datos según una medida de ‘impureza’ que se establezca⁶, cuya finalidad es evaluar cuán desordenados o mezclados están los datos en ese nodo. Este proceso continúa hasta que se cumple un criterio de detención, como la profundidad máxima del árbol o un número mínimo de observaciones en cada nodo.

Consideramos dos versiones base de este algoritmo. *Decision Tree* y *Extra Trees* disponibles en la Librería *Scikit-Learn*. El algoritmo *Decision Tree* constituye la implementación clásica de los árboles de regresión, construyendo su estructura jerárquica de forma iterativa y segmentando los datos en subconjuntos homogéneos (Quinlan, 1986). El método *Extra Trees* selecciona los puntos de corte de forma aleatoria, evitando el riesgo de sobreajuste que pueda causarse por la dependencia excesiva de los datos de entrenamiento (Geurts et al., 2006).

Los hiperparámetros de *Decision Tree* a optimizar fueron: profundidad máxima (*max_depth*), mínimo de muestras para dividir (*min_samples_split*), mínimo de muestras en una hoja (*min_samples_leaf*), máximo de características (*max_features*), valor de complejidad para la poda (*ccp_alpha*) y mínima disminución de impureza (*min_impurity_decrease*). El modelo *Extra Trees* comparte los mismos hiperparámetros que *Decision Tree*, a la vez que se adicionan: número de estimadores (*n_estimators*), muestreo con remplazo (*bootstrap*), máximo de muestras (*max_samples*) y máximo de nodos hoja (*max_leaf_nodes*).

⁶ Pudiendo ser, a modo de ejemplo, el índice de Gini o la entropía.

Random Forest

Random Forest es una técnica introducida en (Breiman, 2001) para mejorar los resultados obtenidos por los árboles de regresión tradicionales, utilizando como base el método *Classification and Regression Tree* (en adelante CART) (Véase: *Classification and Regression Tree* (CART) en **Apéndice A**).

Según (Breiman, 2001), una de las principales ventajas de CART es su simplicidad, capacidad de interpretación y mitigación del riesgo de sobreajuste. No obstante, presenta ciertas limitaciones, como por ejemplo la inestabilidad en las divisiones, lo cual puede llevar al sobreajuste cuando se entrena en muestras específicas. En este sentido, (R. Li & Belford, 2002) señalan que pequeños cambios en los datos de entrenamiento pueden generar resultados de regresión notablemente diferentes.

Random Forest utiliza *bootstrap sampling*, técnica que consiste en generar diferentes subconjuntos de datos a partir de la muestra original mediante selecciones aleatorias con reemplazo. Cada árbol de decisión se construye sobre estas muestras de *bootstrap*, seleccionando predictores de forma aleatoria dentro de un subconjunto de las variables disponibles.

Los hiperparámetros de *Random Forest* a optimizar fueron: número de estimadores (*n_estimators*), profundidad máxima (*max_depth*), mínimo de muestras para dividir (*min_samples_split*), mínimo de muestras en una hoja (*min_samples_leaf*), máximo de características (*max_features*), muestreo con reemplazo (*bootstrap*), máximo de muestras (*max_samples*), mínima disminución de impureza (*min_impurity_decrease*), valor de complejidad para la poda (*ccp_alpha*) y máximo de nodos hoja (*max_leaf_nodes*).

XGBoost (Extreme Gradient Boosting)

Boosting es una técnica de ensamblaje caracterizada por el entrenamiento secuenciado de árboles de regresión. En este proceso, cada modelo n enfoca su aprendizaje considerando los

errores acontecidos en los $n - 1$ modelos previos, asignando un mayor peso a las observaciones que registraron mayores errores de predicción (Freund & Schapire, 1997).

El proceso de entrenamiento de los modelos *Boosting* se divide en dos componentes clave. El primero mide la diferencia entre el valor predicho y el valor real a través de una función de pérdida. El segundo es un término de regularización que penaliza árboles más complejos con el fin evitar el sobreajuste y mejorar la capacidad de generalización del modelo.

En **Apéndice B** se detalla la formulación matemática del algoritmo.

XGBoost es una implementación eficiente del algoritmo de *Boosting*. Fue desarrollado por (Chen & Guestrin, 2016) con el objetivo principal de mitigar el riesgo de *overfitting*.⁷ La característica distintiva de esta implementación es que permite trabajar con datos dispersos (*sparse data*) y efectuar procesamiento en paralelo.

Los hiperparámetros de *XGBoost* a optimizar fueron: número de estimadores (*n_estimators*), profundidad máxima (*max_depth*), tasa de aprendizaje (*learning_rate*), submuestreo (*subsample*), muestra de columnas por árbol (*colsample_bytree*), regularización L1 (*reg_alpha*), regularización L2 (*reg_lambda*), reducción mínima de pérdida (*gamma*) y peso mínimo en nodos hoja (*min_child_weight*).

CatBoost (*Categorical Boosting*)

CatBoost, modelo propuesto en (Prokhorenkova et al., 2018), es un algoritmo basado en la técnica *Boosting* diseñado para emplear datos categóricos de manera eficiente. A diferencia

⁷ El sobreajuste de datos o *Overfitting* acontece cuando un árbol aprende patrones específicos de la base de entrenamiento; hecho que reduce su capacidad de generalizar los resultados a nuevos datos. Para mitigar este problema, se suele emplear diversas técnicas, como la poda, la cual consiste en limitar la profundidad del árbol o el número mínimo de observaciones en cada hoja.

de otras variantes de *Boosting* como *XGBoost* o *LightGBM*, *CatBoost* no requiere de la aplicación de *One Hot Encoding*⁸ para emplear variables categóricas.

Este proceso, inspirado en trabajos como el de (Micci-Barreca, 2001), evita la fuga de información en su aplicación a través de un mecanismo denominado *Ordered Boosting* que asigna permutaciones aleatorias sobre los árboles. De esta forma se asegura que cada transformación solo dependa de datos observados.

Los hiperparámetros de *CatBoost* a optimizar fueron: número de iteraciones (*iterations*), profundidad (*depth*), tasa de aprendizaje (*learning_rate*), regularización L2 en las hojas (*l2_leaf_reg*), número de bordes (*border_count*), subsample (*submuestreo*) y muestra de columnas por nivel (*colsample_bylevel*).

LightGBM (Light Gradient Boosting Machine)

LightGBM es una variante del algoritmo *Boosting* formulada en (Ke et al., 2017) con el objetivo de mejorar la eficiencia, rapidez y escalabilidad del modelo sin comprometer su precisión. Su contribución principal es la incorporación de dos elementos: el *Gradient-based One-Side Sampling* (en adelante GOSS) y el *Exclusive Feature Bundling* (en adelante EFB).

GOSS es una técnica que optimiza el cálculo de la ganancia de información, al conservar las instancias con mayores gradientes y descartar aleatoriamente aquellas con gradientes pequeños; lo que permite una estimación más precisa con menor volumen de datos. Por otra parte, la técnica de EFB enfrenta el desafío de la alta dimensionalidad en grandes volúmenes de datos, mediante la agrupación de características mutuamente exclusivas, reduciendo el número de atributos efectivos sin afectar significativamente el rendimiento del modelo.

Los hiperparámetros de *LightGBM* fueron: número de hojas (*num_leaves*), profundidad máxima (*max_depth*), tasa de aprendizaje (*learning_rate*), número de estimadores

⁸ *One Hot Encoding* es una técnica tradicionalmente utilizada en *Machine Learning* para transformar variables categóricas a un formato numérico que los algoritmos puedan procesar debidamente. Consiste en representar los n valores de determinada variable como un vector binario en n columnas, asignándose un valor de 1 cuando la observación corresponde a esa categoría, y 0 en los casos donde ello no ocurra.

(*n_estimators*), muestras mínimas por nodo hoja (*min_child_samples*), subsample (*submuestreo*), muestra de columnas por árbol (*colsample_bytree*), regularización L1 (*reg_alpha*), regularización L2 (*reg_lambda*) y tipo de boosting (*boosting_type*).

Cox Proportional Hazards

El modelo *Proportional Hazards* o modelo de *Cox*, es un algoritmo clásico en el contexto de análisis de supervivencia. Originalmente introducido por Sir David Cox en (Cox, 1972), permite estimar el tiempo hasta la ocurrencia de un evento específico de interés Y_i , considerando la influencia de distintas covariables X_i . Su principal virtud es la capacidad de ser empleado en presencia de datos censurados, es decir, cuando se desconoce el tiempo exacto del evento en análisis para un porcentaje de las observaciones.

Cox Proportional Hazards fundamenta su funcionamiento en una función de riesgo, que representa la probabilidad de que una observación con ciertas características (recogidas en X_i) experimente el evento en análisis (recogido en Y_i) en un momento dado. Es un modelo semiparamétrico porque no requiere especificar la forma de la función de riesgo basal, lo que lo hace flexible y ampliamente aplicable en diversos ámbitos.

Para la validación del modelo se suele emplear como métrica de referencia el *Concordance Index* (C-Index), que evalúa la capacidad del modelo para ordenar correctamente los tiempos de ocurrencia de un evento en función de los riesgos estimados (Véase: **Estrategias de Validación**).

Los hiperparámetros de *Cox Proportional Hazards* fueron: mínimo de la regularización L2 Ridge (*alpha_min_ratio*) y mínimo de la regularización L1 Lasso (*L1_ratio*).

En **Apéndice C** se detalla la formulación matemática del algoritmo.

Random Survival Forest (RSF)

Random Survival Forest (RSF) es una extensión del algoritmo *Random Forest* introducida en (Ishwaran et al., 2008), diseñado para la modelación de datos de supervivencia. A diferencia de los métodos de árboles de regresión tradicionales, RSF incorpora la variable tiempo hasta el evento como elemento a predecir, además de ser eficiente en el contexto de datos censurados.

Para la construcción de sus árboles, el algoritmo incorpora dos niveles de aleatorización. Por un lado, el uso de una selección aleatoria de un subconjunto de datos definido o *bootstrap*. Por otro, la selección aleatoria de un subconjunto de variables candidatas para la división de nodos, seleccionando en cada caso aquella que optimice la división. Al igual que en *Random Forest*, la incorporación de ambos elementos ayuda a reducir la correlación entre árboles y con ello la capacidad predictiva del modelo.

Los hiperparámetros de *Survival Random Forest (RSF)* fueron: número de estimadores (*n_estimators*), profundidad máxima (*max_depth*), mínimo de muestras para dividir (*min_samples_split*), mínimo de muestras en una hoja (*min_samples_leaf*) y máximo de características (*max_features*).

Marco Teórico para la construcción de las Bases de Datos

Las bases de datos utilizadas, tanto para la modelización tradicional de *Machine Learning* como para la modelización *Survival*, están constituidas por observaciones de duraciones de precios o *Price Spells*; donde cada *spell*, medido en días, es una combinación establecimiento-producto-duración donde el precio permanece incambiado. La modificación de un precio ya sea al alza o a la baja, ocasiona la finalización de un *spell* y el origen de otro.

Para el presente análisis, consideramos la dinámica de precios en Montevideo, Uruguay en el período comprendido entre enero de 2021 y junio de 2024 (Véase: **Fuentes de Información**).

Siguiendo la clasificación de series establecimiento-producto propuesta en (Solórzano & Arango-Castillo, 2024), se construyeron diferentes series para cada combinación establecimiento-producto⁹. En nuestro trabajo se decidió emplear únicamente aquellas series de precio identificadas como *Completed*. Estas series corresponden a observaciones que, para cada par establecimiento-producto, sus correspondientes precios fueron relevados ininterrumpidamente durante el periodo analizado.

Si bien los dos enfoques empleados utilizan series de precios *Completed*, el tratamiento final de los datos en ambas bases fue diferente como consecuencia de las particularidades que tiene cada enfoque.

Los métodos tradicionales de *Machine Learning* asumen que la variable de respuesta es continua y no existen mecanismos de censura que no permitan observar su valor real.¹⁰ Considerando ello, fueron desestimados el primer y el último *spell* de cada par establecimiento-producto dado que la duración registrada en ellos se encuentra condicionada por la definición del período de estudio y, en consecuencia, la duración proyectada no es la correcta. Lo anterior se fundamenta en que estos tipos de modelos no están diseñados para manejar datos con dichas características. La distinción de estos casos respecto al resto de *spells* se encuentra contenida en la variable *Censurado* (Véase: Definición de Variables en **Anexo 3**). En segundo lugar, fueron eliminados valores atípicos o *Outliers* de la variable a predecir *Duración*, distinguiendo previamente según la variable binaria *Promoción*.

Por otro parte, siguiendo a (Ishwaran et al., 2008) los modelos de supervivencia poseen la capacidad de gestionar adecuadamente la censura. Por consiguiente, se optó por no aplicar

⁹ En su trabajo los autores distinguen 5 tipos de series: *Completed*: aquellas series temporales sin faltantes durante el periodo considerado, *Right Censored*: aquellas series temporales incompletas que no fueron relevadas desde el inicio del periodo considerado pero que si llegan al final del mismo, *Left Censored*: aquellas series temporales incompletas que fueron relevadas desde el inicio del periodo considerado pero que no llegan al final del mismo, *Centre Censored*: aquellas series temporales incompletas que no fueron relevadas ni desde el inicio ni hasta el final del periodo considerado pero que si cuentan con una continuidad de datos ininterrumpida en un lapso entremedio e *Interval Censored*: aquellas series temporales incompletas que dan saltos temporales en la periodicidad de su información.

¹⁰ En el caso de los precios, puede ser que el inicio del *spell* fuera antes enero 2021, por lo cual hace se desconoce su inicio o que su finalización fuera luego de junio 2024, por lo cual se desconoce su verdadera fecha de fin. Solamente es posible obtener una aproximación al verdadero valor.

limpieza de datos alguna sobre este tipo de algoritmos, conservando las series de *Price Spells Completed* tal cual fueron definidas en el proceso de construcción de datos.

Estrategias de validación

Dada la heterogeneidad observada en el comportamiento a lo largo de los meses del período de estudio, tanto en relación con la duración de los precios modificados, como en el tamaño de sus respectivos ajustes (Véase: **Análisis Exploratorio**), se optó por definir aleatoriamente los conjuntos de entrenamiento (*Train*) y prueba (*Test*). Considerando que la dimensión de la base de *Price Spells* es amplia (contiene más de 300.000 observaciones), se decidió adoptar una división 70-30% de los conjuntos *Train* y *Test* respectivamente. Esta distribución fue aplicada tanto para los modelos tradicionales de *Machine Learning* como su homólogo en análisis de supervivencia.

Para la medición y evaluación de los modelos tradicionales de *Machine Learning* se optó por utilizar el Error Absoluto Medio o Mean Absolute Error (MAE); el cual mide la diferencia promedio en términos absolutos entre los valores predichos y los valores reales. Con motivo de la heterogeneidad en la duración de los precios entre categorías de productos, se descartó emplear como indicadores primarios al MSE y el RMSE por ser medidas sensibles a desviaciones de estimación grandes. En este contexto MAE es una métrica más adecuada ya que asume que la sobreestimación y subestimación de la duración de los precios tienen el mismo impacto¹¹. Asimismo, dado que el propósito principal de este trabajo es mejorar la precisión predictiva de los modelos en lugar de evaluar su capacidad explicativa, se priorizó el MAE sobre el R^2 . No obstante, los coeficientes de R^2 obtenidos también fueron considerados en la evaluación global del modelo.

En el contexto de los modelos de supervivencia, se utilizó como métrica de evaluación el *Concordance Index* (en adelante, C-Index). Esta métrica evalúa la capacidad predictiva de un modelo con datos censurados de ordenar correctamente los tiempos de ocurrencia de un

¹¹ En otras palabras, predecir un cambio de precio n días antes o n días después tienen una penalización equivalente.

evento en función de los riesgos estimados. El C-Index calcula la proporción de pares concordantes, es decir, aquellos en los que se respeta el orden entre los tiempos predichos y los tiempos observados, de acuerdo con los riesgos calculados por el modelo.

El valor predicho por el C-Index varía entre 0.5 y 1, siendo las estimaciones cercanas al 0.5 equivalentes al azar y las cercanas al 1 indicativas de una concordancia perfecta entre las predicciones y los valores reales. Tradicionalmente, en los estudios empíricos, un valor de 0.7 en el C-Index se considera un indicador de buen desempeño. Valores superiores a 0.7 reflejan una capacidad predictiva adecuada, mientras que magnitudes inferiores indican limitaciones en la precisión del modelo (Royston & Altman, 2013) (Song et al., 2018)

Datos

Fuente de información

Origen, Relevamiento y Alcance Temporal

Para obtener la base de datos se realizó una consulta al Sistema de Información de Precios al Consumidor (SIPC en adelante), órgano perteneciente al Ministerio de Economía y Finanzas (MEF en adelante) del estado de la República Oriental del Uruguay.

La información ¹² es de acceso público y es recopilada diariamente por el SIPC en contacto con distintos supermercados, farmacias y otras tiendas que comercializan una amplia gama de productos predefinidos por el organismo.

Los precios de los distintos artículos en base son reportados automáticamente por los establecimientos que los comercializan, por medio de su sistema de facturación. El decreto N.º 503/006 y ley N 17.250, obliga a los centros a informar correctamente el precio de sus productos, pudiendo quedar sujetos a sanciones en caso de incumplir con la normativa vigente. ¹³ Entre las exigencias estipuladas por el citado decreto, los establecimientos deben informar si el precio reportado constituye o no un precio en oferta, aunque esta información no está sujeta a los mismos controles que los precios.

¹² Puede accederse al Portal del SIPC donde se encuentra el repositorio de bases por medio del siguiente enlace: <https://catalogodatos.gub.uy/dataset/declaraciones-al-sistema-de-informacion-de-precios-al-consumidor-2019>

¹³ Como mecanismo de control en el cumplimiento de la normativa, desde el SIPC se realizan diariamente constataciones de los precios reportados en busca de detectar valores atípicos que pudieran tener como motivo un incorrecto ingreso de estos; en caso de detectar variaciones significativas se procede a comunicarse con el establecimiento en cuestión para la confirmación o rectificación del precio informado.

A efectos de este trabajo se decidió utilizar la información relevada para el departamento de Montevideo durante el período comprendido entre el mes de enero del año 2021 y el mes de junio del 2024.¹⁴

Algunos trabajos empíricos han optado por utilizar la duración en escala mensual o semanal. Para aportar mejores estimaciones e identificar correctamente el momento del cambio de precio, se optó por utilizar un enfoque de evolución de precios diario. Considerando la velocidad de ajuste de precios entre tiendas, un período de información mayor (semana o mes) puede dificultar la detección de ajustes con exactitud.

Transformación y limpieza de los datos.

Con el objetivo de conocer a detalle la composición y comportamiento de los datos, se definieron *Rubros* y *Categorías* las cuales tuvieron como finalidad poder agrupar marcas con características similares. En total se definieron seis rubros (*Alimentos*, *Bebidas con alcohol*, *Bebidas sin alcohol*, *Cuidado Personal*, *Limpieza* y *Papelería*) y treinta categorías (diecisiete pertenecientes al rubro *Alimentos*, dos pertenecientes al rubro *Bebidas con Alcohol*, tres pertenecientes al rubro *Bebidas sin Alcohol*, cuatro pertenecientes al rubro *Cuidado Personal*, dos pertenecientes al rubro *Limpieza* y dos pertenecientes al rubro *Papelería*).¹⁵

Adicionalmente, se efectuó una clasificación de los establecimientos comerciales. Es relevante destacar que la postura tomada en el presente trabajo no tiene como objetivo agrupar establecimientos según su razón comercial, sino en asociar centros comerciales cuyo

¹⁴ El periodo de trabajo fue definido de esa forma considerando la alta granularidad que se obtiene al tomar una cohorte de datos diaria y el sesgo potencial resultante de implementar series temporales extensas. A su vez, se consideró óptimo aislar los efectos económicos ocasionados por la pandemia del COVID-19 acontecida a nivel mundial, la cual afectó notoriamente el comportamiento normal de las economías globalizadas. Por último, se decidió adicionar el primer semestre del 2024 intentando recopilar información lo más actualizada posible, considerando que el presente trabajo inició al cierre del período mencionado.

¹⁵ A modo de ejemplo, la *Manteca Conaprole sin sal Envase 200 grs.* y *Queso rallado Milky Paquete 80 grs.* pertenecen a distintos productos *Manteca* y *Queso Rayado* pero comparten una misma categoría *Lácteos* y rubro *Alimentos*. A su vez, la *Harina trigo común 0000 Cañuelas Paquete 1 kg.* no comparte con ninguno de los anteriores elementos ni producto, ni categoría pero sí rubro: *Alimentos*. Por último, ninguna de estas tres marcas comparte producto, categoría o rubro con *Café envasado (no instantáneo) Chaná Paquete 250 grs.* que pertenece a *Café envasado (no instantáneo)*, *Estimulantes* y *Bebidas sin Alcohol* respectivamente.

criterio de fijación de precios sea vinculante.¹⁶ Aquellos establecimientos donde no fue posible distinguir su razón social ni su red comercial vinculante se decidió etiquetarlos conjuntamente bajo la denominación de ‘*Sin Cadena*’.

Por último, fue adicionado un campo denominado *Tipo de Establecimiento* con el objetivo de clasificar los establecimientos según su giro comercial. Este proceso de clasificación constó de dos etapas y se encuentra detallado en **Anexo 1**. La base final utilizada consta de cinco tipos de establecimientos: *Farmacias, Tiendas Express, Minimercado, Supermercado e Hipermercado*.

En función de la distribución y completitud de los registros se adoptaron secuencialmente las siguientes medidas con el objetivo de conservar la mejor calidad de los datos.

1. Considerar el mayor precio registrado para combinaciones de *ID Establecimiento, ID Producto y Fecha* donde se tuviera más de un registro de precio en un mismo día.
2. Eliminar todos los registros asociados al rubro *Papelería*, debido a su reducida reportabilidad,¹⁷
3. Fijar un mínimo de relevamiento anual de precios para cada combinación establecimiento-producto de, al menos, el 82% del tiempo considerado (300 días en un año o su equivalente a 10 meses¹⁸)¹⁹.

¹⁶ Con esta premisa redes de supermercados como *Red Expres, Ubesur*, etc. son adicionadas como centros vinculantes en el presente trabajo, ya que, si bien los centros comerciales que integran dichas redes no comporten una misma firma propietaria, la fijación de precios entre estos es coordinada.

¹⁷ Se identificó que para el rubro mencionado la información reportada presentaba un comportamiento estacional, solamente recopilándose datos durante los primeros meses del año y por una extensión temporal no mayor a cuatro meses, a excepción del producto *Cinta adhesiva Ready Plast 1 unidad*.

¹⁸ Para el año 2024, en el cual solo se considera un semestre de información, está criterio es escalado a 150 días o su equivalente a 5 meses.

¹⁹ Observando la distribución cronológica de las observaciones se detectó que, para los años considerados, un alto porcentaje de estas cumplen idealmente con ese criterio. Sumado a lo anterior, contemplamos que, por diversos motivos comerciales (fines de semanas, feriados, cuestiones de sazonalidad, etc.), algunos centros comerciales pueden no reportar información durante días específicos, sin ello tener como motivo la clausura del centro comercial o el abandono de la venta de dicho producto.

4. Establecer a cada producto un mínimo descalificativo anual de 30 centros reportados y un mínimo de aceptabilidad segura de 50 centros.²⁰
5. Partiendo desde una óptica establecimiento-producto, se definieron los siguientes principios para la conservación de series y su posterior completitud de faltantes:
 - 5.1 Descartar todas aquellas combinaciones para las cuales se observa algún período de días corridos con faltantes superior a 30 días (mayor a un mes).
 - 5.2 Considerar todas aquellas combinaciones que no tengan una cronología de faltantes mayor a 15 días.
 - 5.3 Para aquellas combinaciones establecimiento-producto que muestran faltantes de forma consecutiva de entre 16 y 30 días, se procedió a analizar los precios ex-ante y ex-post a dicho intervalo, conservando las series cuyos precios coincidiera en los extremos.
6. En aquellas series establecimiento-producto que cumplen con los criterios de selectividad expuestos en los cinco puntos anteriores y que aun así presentan faltantes de datos, se procedió a completar sus series temporales con los valores de los precios previamente registrados a la omisión en cuestión.
7. Utilizando la clasificación de series establecimiento-producto de (Solórzano & Arango-Castillo, 2024) se decidió conservar únicamente aquellas series temporales que no presentan faltantes de precio a lo largo del periodo en estudio, conjunto que se define como *Completed* (véase: **Marco Teórico para la construcción de Bases de Datos**). El objetivo final de las medidas 6 y 7 fue obtener una serie de precios histórica completa.

La base resultante de este proceso de depuración consta de 18.585.458 observaciones distribuidas en 150 productos (76 productos alimenticios, 42 productos de cuidado personal, 18 productos de bebidas sin alcohol, 9 productos de limpieza y 5 productos de bebidas con

²⁰ Se decidió imponer para los años completos un mínimo de exclusión de 30 centros (6,67% de la totalidad de centros en Montevideo) y un mínimo de inclusión de 50 centros (11,11% de la totalidad de centros en Montevideo). Aquellos productos que fueron reportadas por entre 30 y 50 centros fueron analizados comparativamente con otros productos del mismo rubro y categoría, decidiendo conservar aquellos para los cuales no se contaba con una selectividad de productos óptima y descartando quienes ya contaban con una representatividad adecuada. Para el primer semestre del 2024 se adoptó el mismo criterio, reduciendo los márgenes establecidos a la mitad.

alcohol) en un total de 289 establecimientos y conformándose un total de 14.554 combinaciones únicas de establecimiento-producto). En **Anexo 2** se detalla cada uno de los productos considerados.

Los 150 productos considerados en el presente estudio representan el 14.75% de las categorías de productos definidas por el Instituto Nacional de Estadística (en adelante INE) para la elaboración de su Índice de Precios al Consumo (en adelante IPC) y, específicamente, el 27.69% de las divisiones 01, 02, 05 y 13 de dicho índice, siguiendo su reformulación adoptada en el año 2022 (Instituto Nacional de Estadística [INE], 2022).²¹


A partir de la información anterior se definió otro segundo set de datos a los cuales denominamos *Price Spells*. Esta base consiste en la conformación de series temporales para cada combinación establecimiento-producto donde cada registro contiene el tiempo (medido en días por medio de la variable *Duración*) en el cual un precio permanece incambiado. Dado que el comportamiento de establecimientos y productos es heterogéneo, la cantidad de intervalos resultante de la combinación entre ambos varía según la serie en estudio. Asimismo, cada combinación establecimiento-producto tendrá siempre un *spell* más que la cantidad de variaciones de precio acontecidas durante el período, siendo el *spell* adicional el primer registro de precios con el que inicia la base.²²

En la **Figura 1** se presenta ejemplo ilustrativo de cómo se constituye una serie de *Price Spells* para un establecimiento-producto determinado, en el cual se registran tres cambios de precio durante el período en estudio. En dicho ejemplo acontecen tres cambios de precio, generándose consecuentemente cuatro *spells*.

²¹ Las divisiones 01, 02, 05 y 13 son, respectivamente: ‘Alimentos y Bebidas no Alcohólicas’, ‘Bebidas Alcohólicas y Tabaco’, ‘Mobiliario, Enseres Domésticos y Demás Artículos Regulares de los Hogares’ y ‘Cuidado Personal, Protección Social y Bienes Diversos’.

²² En el caso extremo donde no se configuren cambios de precio durante el período en un determinado establecimiento-producto, este tendrá solamente un *spell*, correspondiente al precio con el cual inicia la serie.

Figura 1: Ejemplo ilustrativo de una serie de *Price Spell* para un par establecimiento-producto determinado



La serie de *Price Spells* está conformada por un total de 30 variables. De dicha cantidad 10 fueron comúnmente empleadas en el desarrollo de los modelos de *Machine Learning* y *Survival Machine Learning*, siendo 7 de ellas categóricas (*Cadena*, *Tipo de Establecimiento*, *Categoría*, *Mes*, *Municipio*, *Día del Mes* y *Día de la Semana*), 2 numéricas (*Var Precio %* y *Lag Duración1*) y 1 binaria (*Promoción*). Adicionalmente, para la modelización *Survival Machine Learning* se incorpora *Evento*, variable binaria que indica si la duración proyectada de un *spell* determinado fue observada de forma completa (*Evento = 1*) o no (*Evento = 0*).

En **Anexo 3** se describe a profundidad cada una de las variables.

Para la modelización *Survival Machine Learning* no se efectuaron modificaciones adicionales. En cambio, para los modelos tradicionales de *Machine Learning* fueron impuestas dos condicionantes complementarias. En primer lugar, se descartaron el primer y último intervalo (en caso de haber más de un intervalo) de cada par establecimiento-producto por encontrarse censurados (*Censurado = 1*)²³. En segundo lugar, se decidió prescindir aquellos *spells* que indujeran al sesgo de predicción de un determinado producto por la atipicidad de su duración (*Outliers* o valores atípicos).

La segunda depuración surgió como resultado del análisis individual de cada producto en base. Se entendió que, dada la heterogeneidad en la duración promedio de los *spells* no solo entre rubros sino también entre categorías, la realización de un análisis generalizado podría afectar considerablemente la cantidad de intervalos conservados en productos específicos. Considerando adicionalmente que la duración de los *spells* se encuentra fuertemente condicionada por el estatus promocional del artículo en análisis (Véase: **Análisis**

²³ Los primeros y los últimos intervalos de cada par establecimiento-producto se identifican como censurados porque se desconoce su fecha de inicio y fin respectivamente. Estos *spells* fueron eliminados de la modelización tradicional de *Machine Learning* porque introducen sesgo respecto a la variable a predecir: *Duración*.

Exploratorio), se optó por efectuar dicho análisis por separado según el estatus de esta variable (*En promoción / No en promoción*)..²⁴

Como resultado de la normalización, la base de *Price Spells* utilizada para la modelización de *Machine Learning* tradicional quedó constituida por un total de 301.026 observaciones/*spells*. Por su parte, la misma base para la modelización *Survival* contiene un total de 352.274 observaciones/*spells*; un 17.02% más de registros que la primera.

²⁴ Bajo estas dos premisas se construyeron dos *Boxplots* o *Diagramas de Caja* para cada producto: uno para aquellos casos donde el artículo se encontrará en promoción y otro donde este no lo estuviera. Para ambos casos se definió como criterio de depuración eliminar aquellas observaciones que se encuentren por fuera del espacio comprendido entre el extremo inferior de la caja y el extremo superior de la misma (gráficamente se suele denominar ‘bigotes’ a estos dos extremos),

Análisis Exploratorio

Esta sección tiene como objetivo analizar las principales características de las variables empleadas en los modelos de *Machine Learning* desarrollados²⁵. Como fue definido en la sección de Transformación y limpieza de los datos, la base de *Price Spells* utilizada está compuesta por intervalos de precios para cada combinación existente de establecimiento-producto, siendo la variación de dichos precios lo que da inicio y fin a cada uno de los intervalos.

El análisis exploratorio fue realizado sobre la base de datos utilizada para la modelización tradicional de *Machine Learning*, la cual consiste en todas las combinaciones establecimiento-producto clasificadas como *Completed*, posterior a la depuración realizada por concepto de *Outliers* y datos censurados. Este segmento de base también es compartido por la modelación *Survival*, a la cual no se le efectuaron los anteriores dos procesos de limpieza descritos.

Duración

En **Tabla 1** se muestran los principales estadísticos relacionados con la variable *Duración* para el período estudiado (enero 2021 – junio 2024), tanto para las modelizaciones tradicionales como para la de los modelos *Survival*. Esta segunda modelización contiene 51.248 *spells* más que la primera (17.02%), con una distribución más dispersa y sesgada de los datos. Para el análisis exploratorio subsiguiente se considera exclusivamente el conjunto de datos empleado en los modelos tradicionales.

²⁵ Las variables predictoras son: *Categoría, Promoción, Cadena, Tipo de Establecimiento, Municipio, Mes, Día del Mes, Día de Semana, Var Precio % y Lag DuraciónI*; mientras que la variable a predecir es *Duración*.

Tabla 1: Estadísticos generales de la variable *Duración*

Estadístico	Valores (Modelización <i>Machine Learning</i> Tradicional)	Valores (Modelización <i>Survival Machine Learning</i>)
Cantidad de Observaciones	301.026 (<i>spells</i>)	352.274 (<i>spells</i>)
Duración Media (μ)	38.83 (<i>días</i>)	52.76 (<i>días</i>)
Moda	1 (<i>días</i>)	1 (<i>días</i>)
Desviación Estándar (σ)	65.25 (<i>días</i>)	94.45 (<i>días</i>)
Coefficiente de Variación (CV) ²⁶	167.9%	179.0%
Asimetría	3.63	4.55
Curtosis	22.72	33.34
Duración Mínima	1 (<i>día</i>)	1 (<i>día</i>)
Q25% Duración	2 (<i>días</i>)	4 (<i>días</i>)
Q50% Duración (Mediana)	14 (<i>días</i>)	19 (<i>días</i>)
Q75% Duración	42 (<i>días</i>)	61 (<i>días</i>)
Duración Máxima	1.006 (<i>días</i>)	1.277 (<i>días</i>)
Extremo Inferior ²⁷	1 (<i>día</i>)	1 (<i>día</i>)
Extremo Superior ²⁸	102.0 (<i>días</i>)	146.5 (<i>días</i>)

²⁶ El *Coefficiente de Variación* (CV) es una medida de dispersión relativa que se calcula como la división en la desviación estándar (σ) y la media (μ), escalándose a porcentaje al multiplicar por 100 el anterior cociente: $CV = (\sigma / \mu) \times 100$.

²⁷ & ³⁴ Los extremos inferiores y superiores son dos coeficientes utilizados en los *Boxplots* o *Diagramas de Caja* con el objetivo de mostrar visualmente los límites dentro de los cuales se encuentran la mayoría de las observaciones; aquellos casos que se encuentren por fuera de estos límites suelen denominarse *Valores Atípicos* o *Outliers*. Ambos basan su cálculo en el *Rango Intercuartílico* (RI) el cual se calcula como la diferencia entre el *Tercer Cuartil* (Q75%) y el *Primer Cuartil* (Q25%): (Q75% - Q25%). El extremo inferior se calcula como la diferencia entre el *Primer Cuartil* (Q25%) y el *Rango Intercuartílico* multiplicado por 1.5: (Q25% - 1.5*RI), mientras que el extremo superior se calcula como suma del *Tercer Cuartil* (Q75%) y el *Rango Intercuartílico* multiplicado por 1.5: (Q75% + 1.5*RI)


La duración media de precios de los productos considerados en base es de 38.83 días (equivalente aproximadamente a 1.30 meses), magnitud inferior a la observada en otros trabajos nacionales como (Borraz & Zipitúa, 2013) y (Regueira, 2020) que reportaron duraciones de 2.5 y 3.99 meses respectivamente. No obstante, debe mencionarse que el tratamiento metodológico de estos trabajos, enfocados en el estudio de las dinámicas de precio en Uruguay, difiere del presente estudio en aspectos como: la selección de series, la completitud de faltantes, el tratamiento de *Outliers*, el empleo de observaciones con censura, la utilización de precios en promoción e incluso la selección de productos. Según se pudo corroborar mediante la estimación de los estadísticos presentados bajo otros escenarios de selección de datos, el proceso de transformación y limpieza elegido ocasiona una subestimación parcial de la duración real de los precios.

Similar a (Nakamura & Steinsson, 2008) la mediana en la duración de precios (14 días o su equivalente a 0.47 meses) es significativamente inferior a la media (38.83 días o su equivalente a 1.3 meses), diferencia que puede ser atribuida tanto a la heterogeneidad entre rubros como a la presencia de precios promocionales.

El desvío estándar de la variable a predecir con respecto a su media denota una alta heterogeneidad en la duración de los *spells* entre pares establecimiento-producto. La proximidad entre el valor mínimo y el primer cuartil (Q25) (e incluso la mediana (Q50)), en contraste con la mayor distancia respecto al tercer cuartil (Q75) y el valor máximo, complementan la interpretación anterior.

En la **Figura 2**, que muestra el histograma de la distribución de las duraciones de los *spells*, se observa una asimetría positiva, lo que indica la prevalencia de *spells* de corta duración. Los valores de asimetría (3.63) y curtosis (22.72) presentados en la **Tabla 1**, complementan esta interpretación, evidenciando una distribución sesgada a la derecha con una cola larga que se extiende hasta poco más de 1.000 días. (Ellis, 2009) evidenció un comportamiento similar para Reino Unido entre 2005 y 2008.


Figura 2: Distribución de *Duración* de los spells



En **Figura 3** se proyecta la duración media de los *spells* durante el periodo de estudio: enero 2021 – junio 2024. Dicha evolución se encuentra condicionada por la eliminación de los *spells* 1 y *n* de cada par establecimiento-producto por motivos de censuramiento. Lo anterior implica que los primeros y últimos meses del intervalo se cuente con un bajo volumen de *spells*, ocasionando que el comportamiento observado no sea representativo de la tendencia real.

Los comportamientos observados durante los años 2022 y 2023 evidencian que las mayores duraciones promedio se alcanzan hacia el final de cada año. En enero, se produce un ajuste generalizado de precios que genera la aparición de nuevos *spells* y, en consecuencia, una disminución en la media de duración. Luego del primer trimestre de cada año, se observa un aumento progresivo en la duración promedio, que alcanza su punto máximo al cierre del año, momento en el cual el ciclo vuelve a reiniciarse.

Figura 3: Evolución general de la duración promedio de los spells (enero 2021 – junio 2024)



El comportamiento a la interna de cada *Rubro* puede observarse en la **Figura 8** del **Anexo 4**. El rubro *Bebidas sin Alcohol* presenta una evolución de precios con un patrón muy similar al del modelo general, aunque con duraciones sistemáticamente entre un 10% y un 25% por encima de este. En cambio, *Bebidas con Alcohol* muestra un comportamiento moderadamente alineado con la tendencia general, aunque con duraciones que, en la mayoría de los casos, se encuentran por debajo de esta.

Alimentos y *Cuidado Personal* suelen preformar, respectivamente, por debajo y por encima de la media de la duración general, siguiendo en ambos casos sus mismas oscilaciones. Para ambos rubros en el primer trimestre del 2023 se produce una tendencia opuesta, donde la media de *Duración* en *Alimentos* llega a ser levemente superior a la general y lo inverso acontece con *Cuidado Personal*. Por último, el *Rubro Limpieza* muestra una elevada volatilidad a lo largo del periodo con cambios abruptos que se anticipan a la tendencia general.

Rubro y Categoría

En **Tabla 2** se detalla la composición de la base desde la óptica de *Rubro*:

Tabla 2: Distribución por *Rubro*

Rubro	Obs. (<i>spells</i>) (%) * / **	Prod. (%) * / **	Estab. (%) * / **	Relación Precios P / NP *	Duración Media (μ)	Q50% Duración (Mediana)	Desviación Estándar (σ)
Alimentos	177.196 (58.86%)	76 (57.67%)	255 (88.24%)	36% / 64%	29.22 (<i>días</i>)	12 (<i>días</i>)	48.59 (<i>días</i>)
Bebidas con Alcohol	14.124 (4.69%)	5 (3.33%)	148 (51.21%)	54% / 46%	32.65 (<i>días</i>)	18 (<i>días</i>)	38.09 (<i>días</i>)
Bebidas sin Alcohol	23.202 (7.71%)	18 (12.00%)	240 (83.04%)	30% / 70%	67.37 (<i>días</i>)	32 (<i>días</i>)	97.46 (<i>días</i>)
Cuidado Personal	77.629 (25.79%)	42 (28.00%)	259 (89.62%)	8% / 92%	50.00 (<i>días</i>)	13 (<i>días</i>)	81.57 (<i>días</i>)
Limpieza	8.875 (2.95%)	9 (6.00%)	223 (77.16%)	6% / 94%	68.27 (<i>días</i>)	43 (<i>días</i>)	67.64 (<i>días</i>)
Total	301.026 (<i>spells</i>)	150 prod. **	289 estab. **	28% / 72%	38.83 (<i>días</i>)	14 (<i>días</i>)	65.25 (<i>días</i>)

* ‘Obs.’ = Observaciones | ‘Prod.’ / ‘prod.’ = Productos | ‘Estab.’ / ‘estab.’ = Establecimientos | ‘Relación Precios P / NP’ = Relación Precios en Promoción y No en Promoción

** Los porcentajes en las columnas ‘Observaciones’ y ‘Productos’ indican la proporción del *Rubro* respecto al total de *spells*. En cambio, los porcentajes en la columna ‘Establecimientos’ se calculan sobre el total de establecimientos únicos, dado que un mismo establecimiento puede aparecer en múltiples rubros.

El *Rubro Alimentos* representa el 58.86% de la totalidad de *spells* en base, siendo simultáneamente el que más productos registra (76 productos, 57.67%) y el de menor duración media y mediana (29.22 y 12 días respectivamente). *Cuidado Personal* es el segundo rubro con mayor representatividad de *spells*, siendo relevado por casi 9 de cada 10 establecimientos en base.

Bebidas sin alcohol registra la segunda duración media más alta de la totalidad de *Rubros* (67.37 días), después de *Limpieza* (68.27 días). No obstante, el primer rubro posee la mayor


desviación estándar en la base, lo que puede interpretarse como una alta heterogeneidad en la duración promedio de los *spells* entre las distintas combinaciones establecimiento-producto. La mayor extensión en *Duración* de ambos rubros respecto al resto es parcialmente atribuible al bajo porcentaje de *spells* en promoción.

Analizando la distribución de *spells* a nivel *Categoría*, en el **Figura 9** del **Anexo 4** se observa que la categoría *Higiene Personal*, perteneciente al *Rubro Cuidado Personal*, concentra la mayor cantidad de *spells*, seguido de *Carnes*, *Chacinados*, *Verduras*, *Frutas*, *Lácteos*, *Condimentos & Salsas* y *Arroz* del *Rubro Alimentos*.

En **Figura 4**, se observan las diferencias en la duración de precios entre las distintas categorías. Las categorías *Primeros Auxilios*, *Sal* y *Protección* muestran las mayores dispersiones en las duraciones de precios, conjugando *spells* cortos con *spells* largos. En contraste, las categorías *Frutas*, *Carnes* y *Chacinados* presentan una mayor homogeneidad en la duración de los intervalos de precios, predominando *spells* con pocos días.

La heterogeneidad en la rigidez de precios observada en Montevideo entre los distintos *Rubros* y *Categorías* es consistente con los hallazgos reportados por (Borraz & Zipitúa, 2013) a nivel nacional. Otros estudios regionales e internacionales también llegan a interpretaciones similares respecto a la diversidad en las estrategias de fijación de precios en productos disímiles. (Nakamura & Steinsson, 2008), (Vermeulen et al., 2012), (Ellis, 2009), (Correa et al., 2016), (Kochen, 2016), y (Peña & Prades, 2021).

Figura 4: Distribución de las duraciones de los *spells* por *Categoría*



Cadena y Tipo de Establecimiento

A nivel de Cadenas (**Tabla 11** del **Anexo 4**), se destaca que, *Disco*, *Devoto Express* y *Farmashop* representan conjuntamente casi el 46% de las combinaciones establecimiento-producto. No obstante, *Farmashop* se diferencia de las otras tres cadenas por poseer una duración de *spells* promedio de 51.20 días, por encima de la media total de 38.83; esta diferencia es atribuible a que el 87.73% de sus *spells* en base pertenecen al *Rubro Cuidado Personal*, cuya media de durabilidad precios es mayor a la media general (50 días).

Por otra parte, cadenas como *Kinko*, *Super Tico* y *La Colonial* son quienes presentan las mayores duraciones de precios, superando incluso los 80 días promedio sin variaciones;

opuestamente *San Roque, Disco y Devoto* son los centros con menor sostenimiento de sus precios, todos ellos con duraciones promedio inferior a los 31 días.

Respecto al *Tipo de Establecimiento*, en la **Tabla 12** del **Anexo 4** puede apreciarse que los *Minimercados* son, simultáneamente, quienes tienen la menor cantidad y la mayor duración *spells* (cercana a los 60 días). En contraste, los *Hipermercados* son quienes tienen la menor duración promedio (cercana a los 27 días) y los *Supermercados* quienes tienen la mayor cantidad de *spells* (un total de 124.164).

En **Figura 10** del **Anexo 4** se relacionan, de forma conjunta, las variables *Duración*, *Categoría* y *Tipo de Establecimiento* por medio un mapa de calor. Se proyecta, para cada combinación de *Categoría* y *Tipo de Establecimiento* la *Duración* media estimada.

Variables Cronológicas: Mes, Día del Mes y Día de la Semana

Los indicadores temporales del presente trabajo toman su valor respectivo en función de la fecha en la cual inicia el *spell* que se esté analizando.²⁹

Según lo observado en **Tabla 3**, los ajustes suelen realizarse entre los *lunes* y *miércoles*, concentrando el 57% de los *spells*. Solo poco más del 14% de las modificaciones de precio ocurren durante el fin de semana.

²⁹ A vía de ejemplo, si un intervalo inicia el 01/01/2021 este tendrá como valores asociados enero, 01 y viernes para los features *Mes*, *Día del Mes* y *Día de la Semana* respectivamente.

Tabla 3: Distribución por *Día de la Semana*

Día de la semana	Obs. (<i>spells</i>) (%) * / **	Relación Precios P / NP *	Duración Media (μ)	Q50% Duración (Mediana)	Desviación Estándar (σ)
Lunes	65.658 (21.81%)	26% / 74%	41.81 (<i>días</i>)	16 (<i>días</i>)	65.54 (<i>días</i>)
Martes	51.037 (16.95%)	27% / 73%	40.67 (<i>días</i>)	13 (<i>días</i>)	70.41 (<i>días</i>)
Miércoles	58.902 (19.57%)	31% / 69%	42.04 (<i>días</i>)	19 (<i>días</i>)	63.66 (<i>días</i>)
Jueves	41.571 (13.81%)	29% / 71%	37.29 (<i>días</i>)	14 (<i>días</i>)	70.18 (<i>días</i>)
Viernes	40.536 (13.47%)	37% / 63%	33.06 (<i>días</i>)	6 (<i>días</i>)	59.91 (<i>días</i>)
Sábado	33.210 (11.03%)	24% / 76%	34.80 (<i>días</i>)	11 (<i>días</i>)	55.02 (<i>días</i>)
Domingo	10.102 (3.36%)	13% / 87%	34.26 (<i>días</i>)	4 (<i>días</i>)	67.46 (<i>días</i>)
Total	301.026 (<i>spells</i>)	28% / 72%	38.83 (<i>días</i>)	14 (<i>días</i>)	65.26 (<i>días</i>)


* ‘Obs’ = Observaciones | ‘Relación Precios P / NP’ = Relación Precios en Promoción y No en Promoción

** El porcentaje en la columna ‘Observaciones’ indica la proporción del *Día de la semana* respecto al total de *spells*.

Las duraciones medias más altas / cortas acontecen en los días donde se registran más / menos cantidades de *spells*. Las promociones suelen concentrarse los *viernes*.

En relación con los días del mes (**Figura 5**), los ajustes de precio se concentran entorno a los primeros cuatro días, acumulando casi el 24% del total de *spells*. Esta tendencia se encuentra en línea con lo visto en (Borraz & Zipitría, 2013), quienes señalan que existe una alta concentración de cambios de precio a inicio de cada mes. Sin embargo, debe señalarse que, en dicho trabajo, los cambios de precio son aún más acentuados el primer día de cada mes.


Figura 5: Cantidad de *spells* por *Día del Mes*³⁰



Como se muestra en el **Figura 6**, el mayor volumen de modificaciones de precio se concentra en los primeros dos meses del año. No obstante, ha de señalarse que no existe una tendencia clara en cuanto a la duración media de los intervalos, pues coexisten meses de *spells* largos junto a meses de *spells* cortos (*caso marzo-abril*).

³⁰ Resulta importante recordar que el período de estudio es enero 2021 – junio 2024; ello hace que para los meses comprendidos en el intervalo de enero a junio se tengan registros en cuatro años (2021, 2022, 2023 y 2024), mientras que los meses entre julio y diciembre en tres (2021, 2022 y 2023). Lo anterior ocasiona que la cantidad total de *spells* en los primeros seis meses del año quede sobrerrepresentada con respecto al resto de año. Para aislar este efecto, se entendió conveniente adicionar a la presente figura la cantidad media de *spells* por mes, con el objetivo de representar de mejor manera las proporciones de *spells* a lo largo del año.

Figura 6: Cantidad de *spells* y duración media por Mes



En (Nakamura & Steinsson, 2008) para Estados Unidos también se señala que la mayoría de las variaciones de precio acontecen al inicio de año y posteriormente decrecen. Aunque, a diferencia de dicho estudio, no se observa una clara tendencia al ajuste de precio en el primer mes de cada trimestre.

Municipios

A nivel de municipios, en el **Tabla 13** del **Anexo 4** se observa que el *Municipio CH*, contiene la mayor cantidad de *spells*: 25.28%, alcanzando una duración media de 36.99 días. Esta duración es inferior a la de otros municipios, como el *Municipio F* o el *Municipio D*, ambos con duraciones promedio de 42.17 y 44.29 días respectivamente. Además, se destaca la relevancia del *Municipio B*, que, conjuntamente con el *Municipio CH*, representan casi el 50% del total de *spells*.

Precios: Promoción y Variación de Precios

Siguiendo la **Tabla 4**, el 28.40% de los *spells* de precios fueron clasificados como oferta (*Promoción = 1*), proporción similar a la vista por (Kochen, 2016) para México (31.2%). Asimismo, se observa una duración media significativamente menor de los *spells* en promoción (*Promoción = 1*) respecto de aquellos que no lo están (*Promoción = 0*), entorno al 39.37% de estas últimas.

Tabla 4: Estadísticos de la variable *Duración* discriminando por *Promoción*

Estadístico	Promoción (=1)	No en Promoción (=0)
Cantidad de Observaciones	85.504 (<i>spells</i>) (28.40%)	215.552 (<i>spells</i>) (71.60%)
Duración Media (μ)	18.47 (<i>días</i>)	46.91 (<i>días</i>)
Moda	1 (<i>día</i>)	1 (<i>día</i>)
Desviación Estándar (σ)	30.81 (<i>días</i>)	73.08 (<i>días</i>)
Coefficiente de Variación (CV)	166.8%	155.8%
Asimetría	5.91	3.16
Curtosis	52.09	17.83
Duración Mínima	1 (<i>día</i>)	1 (<i>día</i>)
Q25% Duración	1 (<i>días</i>)	3 (<i>días</i>)
Q50% Duración (Mediana)	11 (<i>días</i>)	15 (<i>días</i>)
Q75% Duración	24 (<i>días</i>)	62 (<i>días</i>)
Duración Máxima	447 (<i>días</i>)	1.006 (<i>días</i>)
Extremo Inferior	1 (<i>día</i>)	1 (<i>día</i>)
Extremo Superior	58.5 (<i>días</i>)	105.5 (<i>días</i>)

La diferencia en la duración temporal de los precios en y fuera de promoción es prácticamente general a todos los estudios revisados que clasifican los precios según esta tipología (Klenow & Kryvtsov, 2008), (Nakamura & Steinsson, 2008), (Ellis, 2009) y (Kochen, 2016).

Analizando las variaciones registradas en los precios de los *spells*, en **Tabla 5** se observa que el 57.82% de los ajustes se corresponden con aumentos de precios. La relación incrementos-disminuciones de precio (57.82% - 42.18%) es similar a la vista para Estados Unidos (57.1% - 42.9%) en (Nakamura & Steinsson, 2008), Brasil, Chile, Colombia y Estados Unidos (57% - 43%, 55% - 45% y 52% - 48% respectivamente) en (Cavallo, 2015) y nacionalmente en (Borraz & Zipitúa, 2013) (60%- 40%).

Tabla 5: Distribución por incrementos y reducciones de *Precio*

Tipo de variación	Obs. (<i>spells</i>) (%) * / **	Relación Precios P / NP * ***	Variación Promedio de Precio (%)	Duración Media	Q50% Duración (Mediana)	Desviación Estándar (σ)
Incremento	174.043 (57.82%)	16% / 84% 28.013 (<i>spells</i>)	19.10%	51.88 (<i>días</i>)	20 (<i>días</i>)	75.73 (<i>días</i>)
Reducción	126.983 (42.18%)	45% / 55% 57.491 (<i>spells</i>)	-13.91%	20.95 (<i>días</i>)	7 (<i>días</i>)	40.98 (<i>días</i>)
Total	301.026 (<i>spells</i>)	28% / 72%	5.18%	38.83 (<i>días</i>)	14 (<i>días</i>)	65.27 (<i>días</i>)

* 'Obs' = Observaciones | 'Relación Precios P / NP' = Relación Precios en Promoción y No en Promoción

** El porcentaje en la columna 'Observaciones' indica la proporción de los incrementos o las reducciones respecto al total de *spells*.

*** La cantidad de *spells* indicada hace referencia a los *spells* en promoción

El 45% de las disminuciones de precio se producen en el contexto de promociones. La prevalencia de las promociones en las reducciones de precio hace que los distintos estadísticos relacionados con la duración (media, mediana, desviación estándar, etc.) sean de menor magnitud en esta óptica comparado con el análisis de los incrementos.

En cuanto a las magnitudes de los ajustes, los aumentos registrados fueron en promedio de 19.10%, mientras que las reducciones de 13.91%. La coexistencia de un mayor valor, en términos absolutos, en la variación incremental de los precios junto con una mayor cantidad de *spells* con esta característica, inducen a suponer que los precios de los productos en análisis tienden en el largo plazo a ajustarse al alza.

El promedio de variabilidad de precios contemplando subas y bajas (5.18%) es similar al visto por (Regueira, 2020) de 3.89% en todo el país. Regionalmente, variaciones porcentuales en el valor de los precios son similares en Chile (16% en aumentos y -14% en disminuciones) y en menor medida Argentina (13% en aumentos y -13% en disminuciones) en (Cavallo, 2015) y para Brasil (16% en aumentos y -13% en disminuciones) en (Correa et al., 2016).

En **Figura 11** y en **Figura 12** del **Anexo 4** se analiza conjuntamente el comportamiento de las variables *Duración* (eje Y), *Var_Precio_%* (eje X) y *Rubro* (puntos), distinguiendo en ambos gráficos si se trata de un incremento o una reducción de precios respectivamente.

Respecto al escenario donde se analizan los aumentos de precio (**Figura 11**), se observa que el rubro *Bebidas sin Alcohol* registra simultáneamente los mayores aumentos promedio de precio y las duraciones promedio más prolongadas. En el extremo opuesto se encuentran *Bebidas con Alcohol* y *Alimentos*, quienes registran conjuntamente los menores ajustes al alza de precios con un menor sostenimiento de estos. En términos generales, puede afirmarse que, bajo la óptica de *Rubros*, los incrementos medios de precio se concentran entre el 10% y el 25%, y dichos ajustes tienen una longevidad promedio de entre 40 y 85 días.

En cuanto a las reducciones de precios (**Figura 12**), los patrones de ajuste detectados son opuestos a los descritos para el caso de los aumentos. Es decir, aquellos rubros que tienden a

ajustar al alza sus precios son quienes suelen efectuar reducciones más profundas y viceversa. Ejemplos claros de esta tendencia son los *Rubros Bebidas sin y con Alcohol* quienes, respectivamente, registraron el mayor y menor promedio de incrementos de precio y que repiten ese mismo comportamiento en las reducciones. En síntesis, bajo la óptica de *Rubros*, las reducciones medias de precio se concentran entre el 10% y el 16%, y presentan una duración promedio de entre 16 y 42 días (ambos extremos cercanos a la mitad de duración que en los aumentos).

Resultados

En este trabajo, se desarrollaron dos enfoques de modelización para estimar la duración de los precios de mercado en Montevideo, Uruguay. El primero se fundamentó en algoritmos tradicionales de *Machine Learning*, con el objetivo de evaluar su capacidad predictiva en la estimación del número de días en que un precio se mantiene incambiado. El segundo se basó en modelos de supervivencia, diseñados para analizar y estimar la probabilidad de ocurrencia de cambios de precios a lo largo del tiempo.

Con relación a la primera modelización, se evaluaron de forma conjunta seis algoritmos de *Machine Learning*: *Decision Tree*, *Extra Trees*, *Random Forest*, *XGBoost*, *CatBoost* y *LightGBM*. Para cada uno de ellos se definió un modelo base o ‘estándar’ como punto de partida, utilizando valores genéricos en sus hiperparámetros. A partir de esta configuración inicial, se llevó a cabo un proceso de ajuste de hiperparámetros, en el cual se exploraron combinaciones múltiples de estos, con el objetivo de identificar aquella que optimizara la métrica de referencia establecida: el error absoluto medio (MAE) (Véase: **Estrategias de validación**).

El modelo que obtuvo el mejor desempeño fue el *XGBoost* con hiperparámetros optimizados, alcanzando un MAE de 8.99 días, seguido de los modelos *Decision Tree* y *CatBoost*, con 9.89 y 12.52 días respectivamente.³¹ Los indicadores fueron calculados sobre la base de *Test*, habiéndose empleado la mejor combinación de hiperparámetros definida en *Train*. La división seleccionada para estos conjuntos fue de 70%-30%.

Utilizando la misma configuración de segmentación de la base y estrategia de validación, se ejecutaron los mismos modelos de forma individual para cada uno de los rubros en base: *Alimentos*, *Bebidas con Alcohol*, *Bebidas sin Alcohol*, *Cuidado Personal* y *Limpieza*. Por

³¹ Cabe destacar que el modelo *XGBoost* no solo presentó el mejor rendimiento en términos de MAE, sino también en las restantes métricas de evaluación: R^2 (0.88), MSE (488.33) y RMSE (22.10)

problemas de *overfitting* ³² fueron desestimados los modelos *LightGBM* de los rubros *Bebidas con Alcohol* y *Limpieza*.

En *Alimentos*, rubro que presenta la mayor cantidad de *spells* en base, el modelo con mejor performance en términos de MAE fue nuevamente el *XGBoost*, con un valor de 8.10 días. No obstante, en los restantes rubros la mejor performance la obtuvieron el modelo *CatBoost* (caso de los rubros *Bebidas con Alcohol* y *Limpieza*, con valores MAE de 11.50 y 18.87 días respectivamente), el modelo *LightGBM* (caso del rubro *Bebidas sin Alcohol* con un valor MAE de 14.79 días) y el modelo *Decision Tree* (caso del rubro *Cuidado Personal* con un valor MAE de 6.76 días).

En **Tabla 6** se presentan los mejores resultados obtenidos en la modelización general y las específicas por rubro según la métrica MAE:

Tabla 6: Mejores Resultados modelización *General* y específica por *Rubro* (*Machine Learning*)

Modelo General o Rubro	Mejor Modelo	Tipo	MAE	MSE	RMSE
General	XGBoost	Hiperparametrización	8.99	488.33	22.10
Alimentos	XGBoost	Hiperparametrización	8.10	292.69	17.11
Bebidas con Alcohol	CatBoost	Hiperparametrización	11.50	489.22	22.12
Bebidas sin Alcohol	LightGBM	Hiperparametrización	14.79	1332.23	36.5
Cuidado Personal	Decision Tree	Hiperparametrización	6.76	657.80	25.65
Limpieza	CatBoost	Hiperparametrización	18.87	1024.03	32.00

³² El *Overfitting* o sobreajuste ocurre cuando un modelo de *Machine Learning* se ajusta demasiado a los datos de entrenamiento, capturando patrones y ruido que no generalizan bien a datos nuevos o no vistos. Es decir, el modelo aprende demasiado bien los datos de entrenamiento, pero pierde capacidad de hacer predicciones precisas en datos desconocidos.

En el **Anexo 5** se ofrece un análisis detallado de los resultados alcanzados para cada modelo, tanto en la modelización general como en las específicas por rubros.

Respecto al enfoque de modelos de supervivencia, se utilizó *Cox Proportional Hazards* y el *Random Survival Forest* (RSF). La métrica de evaluación fue *Concordance Index* (C-Index). Tanto para la modelización general como para la específica por rubros los mejores resultados fueron obtenidos en *Random Survival Forest* (RSF).

En relación con el modelo general, la mejor combinación de hiperparámetros arrojó un C-Index de 0.729. A la interna de los rubros se obtuvieron los siguientes resultados: *Cuidado Personal* (C-Index 0.782), *Limpieza* (C-Index 0.739), *Bebidas sin Alcohol* (C-Index 0.735), *Bebidas con Alcohol* (C-Index 0.732) y *Alimentos* (C-Index 0.731). En todos los casos, el valor del C-Index en *Random Survival Forest* (RSF) fue superior a 0.7, pudiéndose calificar ello como un desempeño destacable, siguiendo lo expuesto en otros estudios empíricos (Royston & Altman, 2013) (Song et al., 2018).

En **Tabla 7** se presentan los mejores resultados obtenidos en la modelización general y las específicas por rubro según la métrica C-Index:

Tabla 7: Mejores Resultados modelización *General* y específica por *Rubro* (*Survival Machine Learning*)

Modelo General o Rubro	Mejor Modelo	C-Index	MAE *
General	Random Survival Forest	0.729	33.10
Alimentos	Random Survival Forest	0.731	26.73
Bebidas con Alcohol	Random Survival Forest	0.732	23.11
Bebidas sin Alcohol	Random Survival Forest	0.735	32.69
Cuidado Personal	Random Survival Forest	0.782	19.31
Limpieza	Random Survival Forest	0.739	26.17

*MAE calculado desconsiderando *spells* censurados por medio de la librería *SurvivalEVAL* (Qi et al., 2024)

En el **Anexo 6** se ofrece un análisis detallado de los resultados alcanzados para cada modelo, tanto en la modelización general como en las específicas por rubros.

Con el fin de poder contrastar los resultados de los modelos tradicionales de *Machine Learning* con sus homólogos *Survival* se optó por calcular para estos últimos una aproximación al error absoluto medio (MAE). En (Qi et al., 2023) se plantea estimar dicho indicador mediante la generación de un conjunto de datos semisintéticos. Utilizando la librería *SurvivalEVAL* (Qi et al., 2024) se procedió a la estimación de dicho indicador, descartando en su cálculo las observaciones censuradas; esto último con el fin de poder comparar los resultados obtenidos en los modelos tradicionales.


Para el modelo general de *Random Survival Forest* (RSF) se obtuvo un MAE de 33.10 días, mientras que los resultados para dicho modelo en cada rubro fueron los siguientes: *Cuidado Personal* (19.31 días), *Bebidas con Alcohol* (23.11 días), *Limpieza* (26.17 días), *Alimentos* (26.73 días), *Bebidas sin Alcohol* (32.69 días).

Los resultados anteriores sugieren que los métodos basados en *Machine Learning* podrían ser más precisos para estimar la duración. No obstante, debe recordarse que ambos enfoques tienen objetivos y metodologías diferentes. Asimismo, para el caso de la modelización tradicional de *Machine Learning*, la selección de los mejores hiperparámetros quedó condicionada de forma directa al menor MAE que se obtuviera en Train, y no así en los modelos *Survival*, donde dicha función fue cumplida por el C-Índex. Por último, cabe señalar que las bases de datos utilizadas para calcular estos estadísticos difieren, lo que limita la fidelidad en la comparación de las estimaciones obtenidas. A pesar de ello, si el usuario final desea una estimación puntual de la duración, el enfoque basado en árboles de regresión parece ser una alternativa superior.

Con el objetivo de conocer los factores que explican el comportamiento de los mejores modelos, efectuamos un estudio de la relevancia de los predictores. Analizando el modelo *XGBoost* hiperparametrizado de la modelización general (**Figura 7**), los predictores *Mes* y *Promoción* resultaron ser los más relevantes, con una importancia del 50.79% y 22.41%

respectivamente. Exceptuando *Tipo de Establecimiento*, el resto de las variables contempladas (*Día de Mes*, *Categoría*, *Var Precio %*, *Cadena*, *Lag DuracionI*, *Municipio*, *Día de semana*) no alcanzan el 5% de interpretabilidad de forma individual.

Figura 7: Relevancia de predictores en el modelo *XGBoost* Optimizado del modelo General



Por último, como podrá constatarse en la **Tabla 8**, la explicabilidad de los predictores varía considerablemente entre rubros. Tanto en *Cuidado Personal* como *Alimentos*, la variable *Mes* obtuvo la mayor relevancia entre todos los predictores, con 79.44% y 48.05% respectivamente. Sin Embargo, en el resto de los rubros su importancia se reduce, exceptuando en *Limpieza* (18.38%). Dentro de *Alimentos*, el segundo predictor en importancia es *Promoción* (24.04%), seguido de *Var_Precio* (7.06%), mientras que en *Cuidado Personal* estas posiciones las ocupan *Tipo de Establecimiento* (7.64%) y *Día de la Semana* (5.44%)

En *Bebidas con Alcohol* y *Bebidas sin Alcohol* los tres predictores más relevantes son *Tipo de Establecimiento*, *Categoría* y *Lag_DuracionI*; siendo esta última la tercera en

significación en ambos casos. Por último, *Limpieza* concentra casi la mitad de su explicabilidad en *Lag Duracion1* (31.27%) y *Mes* (18.38%).

Tabla 8: Relevancia de predictores en la modelización por *Rubro* (*Machine Learning*)

Rubro / Feature	Alimentos	Bebidas con Alcohol	Bebidas sin Alcohol	Cuidado Personal	Limpieza
	Obs *: 177.196 (58.9%) Mejor Modelo: XGBoost	Obs *: 14.124 (4.7%) Mejor Modelo: CatBoost	Obs *: 23.202 (7.7%) Mejor Modelo: LightGBM	Obs *: 77.629 (25.8%) Mejor Modelo: Decision Tree	Obs *: 8.875 (2.9%) Mejor Modelo: CatBoost
Categoría	4.82%	21.24%	15.91%	3.55%	7.90%
Cadena	2.54%	12.22%	11.11%	2.83%	6.19%
Tipo_ Establecimiento	3.51%	22.07%	15.38%	7.64%	4.81%
Mes	48.05%	5.70%	10.84%	79.44%	18.38%
Día_del_mes	4.28%	13.66%	3.38%	0.25%	3.09%
Día_de_la_semana	1.10%	0%	6.93%	5.44%	8.93%
Municipio	2.04%	0.17%	6.76%	0.36%	6.19%
Promoción	24.04%	9.57%	9.07%	0%	4.98%
Var_Precio_%	7.06%	0%	8.89%	0.49%	8.25%
Lag_Duracion1	2.56%	15.38%	11.73%	0%	31.27%

* 'Obs' = Observaciones

Conclusiones

El presente trabajo tuvo como objetivo estudiar la duración de los precios de mercado en Montevideo, Uruguay, utilizando algoritmos tradicionales de *Machine Learning* (*Decision Tree*, *Extra Trees*, *Random Survival Forest*, *XGBoost*, *CatBoost* y *LightGBM*) y modelos de supervivencia (*Cox Proportional Hazards* y *Random Survival Forest* (RSF)). Con este fin fueron empleados 150 productos, que representan el 14.75% de las categorías definidas por el INE³³ para el cálculo del IPC³⁴, en 289 establecimientos, durante el período comprendido entre enero de 2021 y junio de 2024.

La determinación de cambios en los precios comerciales resulta útil tanto para productores como consumidores. Para los productores, permite optimizar estrategias empresariales, anticipando o postergando modificaciones de precios en pos de maximizar márgenes de ganancia. Los consumidores, por su parte, pueden eficientizar la planificación de sus compras, aprovechando promociones y previendo aumentos estacionales, lo que contribuye a mejorar la gestión de su presupuesto y maximizar su poder de compra.

Dentro de los modelos tradicionales, *XGBoost* obtuvo la mejor performance, con un error absoluto medio (MAE) de 8.99 días en su estimación. En cuanto a los modelos de supervivencia, *Random Survival Forest* (RSF) mostró el mejor rendimiento, con un C-Index de 0.729. Con el objetivo de contrastar ambos modelos, calculamos una aproximación al MAE para los modelos de supervivencia, encontrando que los modelos de *Machine Learning* podrían ser más precisos.

Analizando la explicabilidad del modelo *XGBoost* encontramos que los predictores *Mes* y *Promoción* concentran gran parte de la ganancia, con una relevancia del 50.79% y 22.41% respectivamente.

³³ Índice de Precios al consumo (IPC).

Con el objetivo de mejorar la precisión en grupos específicos, se realizaron análisis individualizados por *Rubro*, obteniéndose diferentes modelos óptimos: *XGBoost* en *Alimentos*, *LightGBM* en *Bebidas sin Alcohol*, *Decision Tree* en *Cuidado Personal* y *CatBoost* en *Bebidas con Alcohol* y *Limpieza*. El análisis de importancia de variables efectuado para cada subgrupo sugiere la existencia de un comportamiento heterogéneo; hecho que induce a pensar que no solamente no existe un único mejor modelo, sino que los factores que determinan la duración de precios también puede variar.

Si bien la utilización de datos diarios aportó una mayor riqueza informativa, los resultados obtenidos deben interpretarse a la luz de algunas limitaciones.

La rigurosidad impuesta en la completitud de datos limitó considerablemente el alcance del estudio, impidiendo el desarrollo de un análisis extensible a todo el país como consecuencia del bajo relevamiento de centros en algunos departamentos.³⁵ Asimismo, las condiciones de limpieza de datos impuesta desbalancearon la proporción de *Categorías* y *Rubros* definida, ocasionando, por ejemplo, que se desestimara enteramente el rubro *Papelería* o que prevalecieran más productos alimenticios que de bebidas con y sin alcohol.

Futuros estudios podrían considerar información adicional relacionada con el consumo de bienes de los hogares uruguayos, optimizar las categorías definidas y asignarles una ponderación diferenciada, en caso de ser necesario.

Si bien nuestro trabajo abarcó la utilización de modelos tradicionales y *Survival de Machine Learning*, futuras líneas de trabajo podrían contemplar la utilización de otras metodologías, como modelos econométricos o redes neuronales. Asimismo, sería relevante incorporar nuevas variables explicativas que permitan arribar a una mejor comprensión de los mecanismos que influyen en la duración de los precios. A modo de ejemplo, en este trabajo no se aisló el efecto de la pandemia de COVID-19 ni se consideraron variables macroeconómicas que podrían ser relevantes.

³⁵ Sistema de Información de Precios al Consumidor (SIPC)

Apéndice

Apéndice A: Classification and Regression Tree (CART)

Formalmente, *CART* (*Classification and Regression Tree*) es un problema de regresión con p predictores $(X_1, X_2, \dots, X_p)$ y una variable de respuesta continua (Y), donde se divide el espacio de predictores en dos regiones no superpuestas R_1 y R_2 según un predictor X_j y un punto de división s tal que se minimice la suma de los errores cuadrados:

$$\sum_{i: x_i \in R_1(j, s)} (y_i - \bar{y}_{R_1})^2 + \sum_{i: x_i \in R_2(j, s)} (y_i - \bar{y}_{R_2})^2$$

Donde $\bar{y}_{R_1}$ y $\bar{y}_{R_2}$ son las medias de las observaciones de Y en las regiones R_1 y R_2 respectivamente; siendo dichas regiones definidas como:

$$R_1(j, s) = \{X \mid X_j < s\}, \quad R_2(j, s) = \{X \mid X_j \geq s\}$$

El procedimiento de división se repite para todas las regiones subsiguientes hasta cumplir con un criterio de detención. La aleatorización en la selección de predictores para cada nodo reduce la correlación entre los árboles individuales, haciendo que *CART* sea menos propenso a sobreajustar el modelo y más robusto ante nuevas muestras de datos.

Con el fin de optimizar su desempeño predictivo, se efectuaron iteraciones consecutivas sobre diversos hiperparámetros del modelo; proceso comúnmente denominado como hiperparametrización (Breiman, 2001; Probst & Boulesteix, 2018).

Apéndice B: Boosting

Dado un conjunto de datos con n observaciones y p predictores $(x_1, x_2, \dots, x_p)$, el modelo se construye iterativamente, donde en cada paso t , un árbol de decisión $f_t(x)$ se ajusta para minimizar la siguiente función objetivo:

$$L(t) = \sum_{i=1}^n l(y_i, \hat{y}_i^{t-1} + f_t(x_i)) + \Omega(f_t),$$

donde $l(y_i, \hat{y}_i)$ es la función de pérdida, que se define como el error cuadrático medio (MSE). Por su parte $\Omega(f_t)$ es el término de regularización que penaliza la complejidad del modelo, definido como:

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2,$$

donde T es el número de hojas del árbol, γ controla la penalización por hojas adicionales, y λ regula los valores de los pesos de las hojas w_j^2 . El modelo ajusta los árboles $f_t(x)$ iterativamente para reducir el error cuadrático acumulado, maximizando la ganancia en la función objetivo en cada partición del árbol. Este proceso continúa hasta alcanzar un criterio de detención.

Apéndice C: Cox Proportional Hazards

El modelo de *Cox Proportional Hazards* se basa en la función de riesgo $h(t | x)$, que representa la probabilidad de que un individuo con ciertas características experimente el evento en un momento dado. La fórmula general del modelo es:

$$h(t | x) = h_0(t) \exp(x\beta),$$

donde $h_0(t)$ es una función de riesgo basal que describe como varía el riesgo del evento a lo largo del tiempo en ausencia de covariables, x es el vector de covariables y β son los coeficientes que cuantifican el efecto de las covariables sobre el riesgo.

Anexos

Anexo 1: Definición de la variable: Tipo de Establecimiento.

La variable *Tipo de Establecimiento* fue incorporada con el objetivo de agrupar conjuntamente establecimientos que compartan giro comercial o una misma estructura de ventas. Este proceso constó de dos etapas secuenciadas que se detallan a continuación:

1ra Etapa: Se distinguió aquellos centros cuyos bienes comercializados (caso *Tienda Especializada* y *Farmacia*), modalidad de venta (caso *Tienda Express*) y canal de ventas (caso *E-Commerce*), fueran características condicionantes o determinísticas de la modalidad y/o del tipo de producto a vender por el centro en consideración.

2da Etapa: Para aquellos establecimientos cuyo tipo comercial no puede ser clasificado, ni por su formato de venta ni por los productos que vende, decidió emplearse como criterio clasificador la cantidad de cajas presentes en el establecimiento (dato suministrado de origen por el SIPC). De esta forma, se denominaron *Hipermercado* aquellos centros comerciales con más de 15 centros de cobro, *Supermercado* si dicha magnitud se encuentra entre 4 y 14, y *Minimercado* si esa cantidad es inferior o igual a 3.

Cabe señalar que, como consecuencia del criterio de clasificación adoptado en esta etapa, establecimientos pertenecientes a un misma cadena o nexo comercial pueden no estar en una misma categoría de *Tipo de Establecimiento*, aconteciendo casos donde una misma *Cadena* puede tener puntos de venta distinguidos como hipermercados, supermercados y minimercados conjuntamente. De esta forma puede afirmarse que, a diferencia de lo que ocurre en la clasificación de los productos con *Rubro* y *Categoría*, *Cadena* y *Tipo de Establecimiento* no son vinculantes.

Como resultado del proceso de normalización y depuración, la finalmente utilizada consta únicamente de los siguientes tipos de establecimiento: *Farmacias, Tienda Express, Hipermercado, Supermercado y Minimercado.*

Anexo 2: Productos considerados

Se detalla a continuación los 150 productos considerados en base, agrupados por su respectiva *Categoría y Rubro*:

Tabla 9: Productos considerados

Rubro	Categoría	Cant. Productos	Productos
Alimentos	Aceites	7	Aceite de girasol Óptimo Envase 900 cc Aceite de girasol Río de la Plata Envase 900 cc Aceite de girasol Uruguay Envase 900 cc Aceite de maíz Delicia Envase 900 cc Aceite de maíz Río de la Plata Envase 900 cc Aceite de soja Condesa Envase 900 cc Aceite de soja Río de la Plata Envase 900 cc
Alimentos	Arroz	5	Arroz blanco Aruba tipo Patna Bolsa 1 kg. Arroz blanco Blue Patna Bolsa 1 kg. Arroz blanco Green Chef Bolsa 1 kg. Arroz blanco Saman Blanco Bolsa 1 kg. Arroz blanco Vidarroz Bolsa 1 kg.
Alimentos	Azúcar	2	Azúcar blanco Azucarlito Paquete 1 kg. Azúcar blanco Bella Unión Paquete 1 kg.
Alimentos	Carnes	10	Aguja vacuna Con Hueso - Sin Marca 1 kg. Aguja vacuna Sin Hueso - Sin Marca 1 kg. Carne picada vacuna Con Hasta 20% de grasa 1 kg. Carne picada vacuna Con Hasta 5% de grasa 1 kg. Hamburguesas carne vacuna Burgy Paquete 3 unidades Hamburguesas carne vacuna Schneck Paquete 2 unidades Nalga vacuna Sin Hueso - Sin Marca 1 kg. Peceto vacuno Sin Marca 1 kg. Pescado fresco bifes de merluza - sin marca 1 kg. Pollo entero fresco con menudos Avícola del Oeste 1 kg.
Alimentos	Chacinados	9	Chorizos mezcla sueltos - Cattivelli - Extra 1 kg. Chorizos mezcla sueltos - Centenario - Extra 1 kg. Chorizos mezcla sueltos - La Familia - Hilo amarillo 1 kg. Frankfurters cortos Ottonello Paquete 8 us. Frankfurters cortos Schneck Paquete 8 us. Jamón cocido no artesanal Ottonello 1 kg. Leonesa Schneck 1 kg. Paleta vacuna Con Hueso - Sin Marca 1 kg. Paleta vacuna Sin Hueso - Sin Marca 1 kg.
Alimentos	Condimentos y Salsas	5	Mayonesa común Hellmans Envase 500 grs. Mayonesa común Uruguay Envase 500 grs. Pulpa de tomate Conaprole Envase 1 lt. Pulpa de tomate De Ley Envase 1,020 lt. Pulpa de tomate Gourmet Envase 1 lt.

Rubro	Categoría	Cant. Productos	Productos
Alimentos	Dulces	6	Dulce de leche Conaprole Envase 1 kg. Dulce de leche Los Nietitos Envase 1 kg. Dulce de leche Manjar Envase 1 kg. Dulce de membrillo Los Nietitos Envase 400 grs. Mermelada de durazno El Hogar Envase 500 grs. Mermelada de durazno Los Nietitos Envase 500 grs.
Alimentos	Enlatados	1	Arvejas en conserva Cololó Lata 380 grs.
Alimentos	Fideos	4	Fideos secos al huevo Adria Paquete 500 grs. Fideos secos al huevo Cololó Paquete 500 grs. Fideos secos al huevo Las Acacias Paquete 500 grs. Fideos secos semolados Las Acacias - franja celeste Paquete 500 grs.
Alimentos	Frutas	1	Tomate Americano, 1.0 kilogramos
Alimentos	Harinas	6	Harina de maíz Presto Pronta Arcor Paquete 500 grs. Harina de maíz Puritas Paquete 450 grs. Harina trigo común 000 Cañuelas Paquete 1 kg. Harina trigo común 0000 Cololó Paquete 1 kg. Harina trigo común 0000 Primor Paquete 1 kg.
Alimentos	Huevos	3	Huevos colorados El Jefe Envase 1/2 docena Huevos colorados Prodhin Envase 1/2 docena Huevos colorados Super huevo Envase 1/2 docena
Alimentos	Lácteos	8	Manteca Conaprole sin sal Envase 200 grs. Manteca Kasdorf Envase 200 grs. Margarina Dorian nueva Envase 250 grs. Queso rallado Artesano Paquete 80 grs. Queso rallado Conaprole Paquete 80 grs. Queso rallado Milky Paquete 80 grs. Yogur Calcar Sachet 1 lt. Yogur Conaprole BIO TOP Sachet 1,200 lt.
Alimentos	Panificados	2	Galletitas al agua Famosa Paquete 140 grs. Pan de molde lacteado Bimbo Paquete 330 grs.
Alimentos	Postres	2	Helado familiar Conaprole Envase 1lt. Helado familiar Crufi Envase 1lt.
Alimentos	Sal	2	Sal fina yodada fluorada Sek Paquete 500 grs. Sal fina yodada fluorada Urusal Paquete 500 grs.
Alimentos	Verduras	3	Lechuga Crespa, 1.0 unidad Papa Blanca, 1.0 kilogramos Papa Rosada, 1.0 kilogramos
Bebidas con Alcohol	Cervezas	3	Cerveza Patricia Botella 960 ml. Cerveza Pilsen Botella 960 ml. Cerveza Zillertal Botella 1 lt.
Bebidas con Alcohol	Vinos	2	Vino tinto común tetrabrick Faisán Envase 1 lt. Vino tinto común tetrabrick Santa Teresa Clásico Envase 1 lt.

Rubro	Categoría	Cant. Productos	Productos
Cuidado Personal	Protección	9	Júpiter Aerosol, 165 cm3 Júpiter Crema, 80.0 gramos Off! Family Aerosol, 144cm3 Off! Family Crema, 200.0 gramos Protector solar SPF 20 Dermaglós 250 milímetros Protector solar SPF 30 Hawaiian Tropic 180 ml. Protector solar SPF 40 Dermaglós 250 milímetros Protector solar SPF 50 Eucerin 150 ml. Protector solar SPF 60 Soundown 120 ml.
Limpieza	Jabón de Ropa	4	Jabón en polvo máquina Drive Paquete 800 grs. Jabón en polvo máquina Skip - Paquete azul Paquete 800 grs. Jabón para ropa en barra Bull Dog Unidad 300 grs. Jabón para ropa en barra Nevex Unidad 200 grs.
Limpieza	Limpieza de Hogar	5	Detergente para vajilla Deterjane limón Envase 1.250 lt. Detergente para vajilla Hurra Nevex Limón Envase 1.250 lt. Hipoclorito de sodio Agua Jane Botella 1 lt. Hipoclorito de sodio Sello Rojo Botella 1 lt. Hipoclorito de sodio Solución Cristal Botella 1 lt.

Anexo 3: Descripción de variables definidas

Se describe a continuación las 30 variables definidas en el presente trabajo. En **negrita** se señalan los 10 features utilizados en las modelaciones de *Machine Learning* y *Survival Machine Learning* y en color rojo la variable a predecir.

Tabla 10: Variables definidas

Variable	Descripción
Año	Año en el que inicia un <i>spell</i> o intervalo de precio. (Ejemplo: 2021 para la fecha 01/01/2021)
Barrio	Barrio donde se localiza el establecimiento en cuestión. (Ejemplo: Pocitos)
Cadena	Cadena a la cual pertenece el establecimiento en cuestión. (Ejemplo 'Farmashop')
Categoría	Categoría a la cual pertenece el producto en cuestión. (Ejemplo: 'Aceites' para el producto 'Aceite de girasol').
Censurado	Variable binaria 0-1 que indica si un <i>spell</i> o intervalo se encuentra (1) o no censurado (0).
Día_de_la_semana	Nombre del día de la semana en el cual inicia un <i>spell</i> o intervalo de precio. (Ejemplo: Viernes para la fecha 01/01/2021)
Día_del_mes	Número de día del mes en el cual inicia un <i>spell</i> o intervalo de precio. (Ejemplo: 1 para la fecha 01/01/2021)
Duración	Cantidad de días de un <i>spell</i> o intervalo (Ejemplo: 10 si un <i>spell</i> o intervalo inicia el 01/01/2021 y finaliza el 10/01/2021).
Evento	Variable binaria 0-1 que indica si la duración proyectada de un <i>spell</i> o intervalo es completa (1) o no (0). Matemáticamente, evento se define de la siguiente manera: $\text{Evento} = 1 - \text{Censurado}$
Fecha_fin	Fecha en la que finaliza un <i>spell</i> o intervalo (Ejemplo 10/01/2021 si un <i>spell</i> o intervalo inicia en un momento dado y finaliza el 10/01/2021).
Fecha_inicio	Fecha en la que inicia un <i>spell</i> o intervalo (Ejemplo 01/01/2021 si un <i>spell</i> o intervalo inicia el 01/01/2021 y finaliza en un momento dado).
Feriado	Variable binaria 0-1 que indica si en <i>spell</i> o intervalo de precio hubo, al menos, un feriado (Ejemplo: si un <i>spell</i> o intervalo inicia el 01/01/2021 y finaliza el 10/01/2021 corresponderá que la variable tome el valor del 1 como consecuencia de los feriados del 01/01/2021 y del 06/01/2021) (Hubo al menos un feriado = 1 / No hubieron feriados = 0).

Variable	Descripción
ID_establecimiento	Número de identificación del establecimiento en cuestión. ³⁶
ID_producto	Número de identificación del producto en cuestión. ¹⁹
Incremento	Variable binaria 0-1 que indica si el precio aumentó (1) o no (0) con respecto al <i>spell</i> anterior. (Ejemplo: si en un intervalo <i>t-1</i> el precio fue \$50 y en el siguiente intervalo <i>t</i> el mismo asciende a \$60, el valor que tomará la variable Incremento será de 1)
Intervalo (o <i>spell</i>)	Numero de <i>spell</i> o intervalo del par establecimiento-producto en cuestión. (Ejemplo: para el primer intervalo de una serie el número asignado en esta variable es 1, para el segundo 2 y así sucesivamente).
Lag_Duración1	Precio del intervalo o <i>spell</i> anterior (t-1) al intervalo en análisis (t). (Ejemplo: si en un intervalo <i>t-1</i> el precio fue \$50 y en el siguiente intervalo <i>t</i> el mismo asciende a \$60, el valor que tomará la variable Lag_Duración1 será de 50).
Mes	Número de mes en el que inicia un <i>spell</i> o intervalo de precio. (Ejemplo: 1 para la fecha 01/01/2021)
Municipio	Municipio en donde se localiza el establecimiento en cuestión. (Ejemplo: Municipio CH para un establecimiento que se encuentra en el barrio Pocitos)
Nombre	Nombre del producto en cuestión. (Ejemplo: 'Aceite de girasol Óptimo Envase 900 cc')
Nombre_sucursal	Nombre del establecimiento en cuestión. (Ejemplo: 'BELA 1')
Precio	Precio del producto durante el <i>spell</i> . /Ejemplo: 50 para un precio de \$50)
Promoción	Variable binaria que toma el valor (0) en caso de no ser un <i>spell</i> en promoción y (1) en caso de que sí lo sea. El criterio adoptado para clasificar un <i>spell</i> como promoción o no es considerar como fue informado el primer día del mismo. ³⁷
Reducción	Variable binaria 0-1 que indica si el precio disminuyó (1) o no (0) con respecto al <i>spell</i> anterior. (Ejemplo: si un intervalo <i>t-1</i> en precio fue \$50 y en el siguiente intervalo <i>t</i> el mismo asciende a \$60, el valor que tomará la variable Reducción será de 0)

³⁶ Definido por defecto por el SIPC

³⁷ Este criterio fue adoptado con motivo a que se identificaron casos de spells donde, ante un mismo precio, se obtuvieron respuestas diferentes en cuanto a la promoción o no del producto en cuestión. Dado que el centro del presente estudio es conocer la magnitud e importancia de las duraciones de los precios, el estado o no en promoción pasa a ser una característica secundaria, lo que amerita a no poner énfasis en cambios en el estado de la promoción sin un simultáneo inicio de un nuevo spell.

Variable	Descripción
Rolling_Mean_Duración	Media de precios histórica previo al intervalo en cuestión. ³⁸ <i>(Ejemplo: si, ubicados en el tercer intervalo de la serie, los precios de los dos intervalos previos fueron, indistintamente, \$50 y \$60, entonces el valor que tomará Rolling_Mean_Duración en el intervalo en análisis será \$55).</i>
Rubro	Rubro al cual pertenece el producto en cuestión. <i>(Ejemplo: Alimentos para el producto Aceite de girasol).</i>
Tipo_establecimiento	Categorización asignada a cada establecimiento según, o bien los bienes que comercializa, o bien la cantidad de cajas presentes en el mismo ³⁹ . <i>(Ejemplo: Farmacia para la cadena ‘Farmashop’).</i>
Trimestre	Trimestre (Q1, Q2, Q3 o Q4) en el que inicia un <i>spell</i> o intervalo de precio. <i>(Ejemplo: Q1 para la fecha 01/01/2021)</i>
Var_±_10%	Variable binaria 0-1 que indica si el precio de un intervalo t aumento o disminuyó más de un 10% respecto al intervalo t-1 anterior (1) o dicha magnitud de cambio fue de menor valor (0). <i>(Ejemplo: si en un intervalo t-1 el precio fue \$50 y en el siguiente intervalo t el mismo asciende a \$60, el valor que tomará la variable Var_±_10% será de 1, ya que el aumento registrado fue superior al 10%).</i>
Var_Precio	Variación numérica en el valor del precio respecto al intervalo anterior, conservando el signo de la dirección en el cambio del precio. <i>(Ejemplo: si en un intervalo t el precio fue \$50 y en el siguiente intervalo t+1 el mismo asciende a \$60, el valor que tomará la variable Var_Precio será de 10).</i>
Var_Precio_%	Variación relativa en el valor del precio respecto al intervalo anterior, conservando el signo de la dirección en el cambio del precio. <i>(Ejemplo: si un intervalo t el precio fue \$50 y en el siguiente intervalo t+1 el mismo asciende a \$60, el valor que tomará la variable Var_Precio_% será de 20).</i>


³⁸ La medida no pondera los valores de precio de cada *spell* por la cantidad de días que estos hayan tenido como duración.

³⁹ Para más detalle de la definición de Tipo de Establecimiento ver **Anexo 1: Definición de la variable: Tipo de Establecimiento.**


Anexo 4: Complemento de Análisis Exploratorio

Figura 8: Evolución por *Rubro* de la duración promedio de los *spells* (enero 2021 – junio 2024)


1. Alimentos




2. Bebidas con Alcohol



3. Bebidas sin Alcohol



4. Cuidado Personal



5. Limpieza




Figura 9: Distribución de *spells* por *Categoría*




Tabla 11: Distribución por *Cadena*

Cadena	Obs. (<i>spells</i>) (%) * / **	Estab. * / **	Prod. * / **	Relación Precios P / NP *	Duración Media (μ)	Q50% Duración (Mediana)
Disco	61.301 (22.03%)	20 (6.92%)	80 (53.33%)	47% / 53%	21.97 (<i>días</i>)	6 (<i>días</i>)
Devoto Express	56.276 (18.69%)	28 (9.69%)	76 (50.67%)	40% / 60%	30.99 (<i>días</i>)	12 (<i>días</i>)
Farmashop	49.308 (16.38%)	70 (24.22%)	40 (26.67%)	0% / 100%	51.20 (<i>días</i>)	4 (<i>días</i>)
Devoto	35.390 (11.76%)	17 (5.88%)	80 (53.33%)	51% / 49%	30.39 (<i>días</i>)	12 (<i>días</i>)
Red Express	22.646 (7.52%)	10 (3.46%)	113 (75.33%)	17% / 83%	47.68 (<i>días</i>)	30 (<i>días</i>)
Sin Cadena	8.658 (2.88%)	9 (3.11%)	133 (88.67%)	9% / 91%	56.27 (<i>días</i>)	31 (<i>días</i>)
Supermercados Grupal	8.067 (2.68%)	6 (2.08%)	129 (86.00%)	19% / 81%	47.60 (<i>días</i>)	29 (<i>días</i>)
Red Market	7.630 (2.53%)	8 (2.77%)	130 (86.67%)	15% / 85%	57.48 (<i>días</i>)	33 (<i>días</i>)
San Roque	7.442 (2.47%)	15 (5.19%)	14 (9.33%)	0% / 100%	27.25 (<i>días</i>)	3 (<i>días</i>)
Tienda Inglesa	6.651 (2.21%)	8 (2.77%)	44 (29.33%)	26% / 74%	44.47 (<i>días</i>)	24 (<i>días</i>)
Macromercado Mayorista	6.528 (2.17%)	4 (1.38%)	81 (54.0%)	5% / 95%	37.81 (<i>días</i>)	21 (<i>días</i>)
Kinko	6.218 (2.07%)	27 (9.34%)	32 (21.33%)	7% / 93%	90.96 (<i>días</i>)	81 (<i>días</i>)

* ‘Obs.’ = Observaciones | ‘Prod.’ / ‘prod.’ = Productos | ‘Estab.’ / ‘estab.’ = Establecimientos | ‘Relación Precios P / NP’ = Relación Precios en Promoción y No en Promoción

** Los porcentajes en las columnas ‘Observaciones’ y ‘Productos’ indican la proporción de la *Cadena* respecto al total de *spells*. En cambio, los porcentajes en la columna ‘Establecimientos’ se calculan sobre el total de establecimientos únicos, dado que un mismo establecimiento puede aparecer en múltiples cadenas.

Cadena	Obs. (<i>spells</i>) (%) * / **	Estab. * / **	Prod. * / **	Relación Precios P / NP *	Duración Media (μ)	Q50% Duración (Mediana)
Pigalle	4.454 (1.48%)	17 (5.88%)	18 (12.00%)	44% / 56%	64.90 (<i>días</i>)	41 (<i>días</i>)
Super Tico	3.008 (1.00%)	5 (1.73%)	106 (70.67%)	0% / 100%	90.23 (<i>días</i>)	66 (<i>días</i>)
Frigo	2.695 (0.90%)	3 (1.04%)	102 (68.00%)	20% / 80%	51.95 (<i>días</i>)	30 (<i>días</i>)
Grupal	1.883 (0.63%)	1 (0.35%)	108 (72.00%)	21% / 79%	45.05 (<i>días</i>)	29 (<i>días</i>)
Géant	1.815 (0.60%)	1 (0.35%)	81 (54.00%)	48% / 52%	33.18 (<i>días</i>)	14 (<i>días</i>)
Micro Macro	1.586 (0.53%)	2 (0.69%)	54 (36.00%)	2% / 92%	35.12 (<i>días</i>)	16 (<i>días</i>)
La Colonial	1.446 (0.48%)	4 (1.38%)	60 (40.00%)	0% / 100%	85.18 (<i>días</i>)	71 (<i>días</i>)
Ubesur	1.364 (0.45%)	1 (0.35%)	94 (62.67%)	27% / 73%	56.68 (<i>días</i>)	31 (<i>días</i>)
Tamisur	932 (0.31%)	1 (0.35%)	87 (58.00%)	0% / 100%	63.04 (<i>días</i>)	37 (<i>días</i>)
Ta -Ta	367 (0.12%)	13 (4.50%)	11 (7.33%)	1% / 99%	34.09 (<i>días</i>)	15 (<i>días</i>)
Frog	361 (0.12%)	19 (6.57%)	1 (0.67%)	32% / 78%	44.58 (<i>días</i>)	31 (<i>días</i>)
Total	301.026 (<i>spells</i>)	289 estab. **	150 prod. **	28% / 72%	38.83 (<i>días</i>)	14 (<i>días</i>)

* ‘Obs.’ = Observaciones | ‘Prod.’ / ‘prod.’ = Productos | ‘Estab.’ / ‘estab.’ = Establecimientos | ‘Relación Precios P / NP’ = Relación Precios en Promoción y No en Promoción

** Los porcentajes en las columnas ‘Observaciones’ y ‘Productos’ indican la proporción de la *Cadena* respecto al total de *spells*. En cambio, los porcentajes en la columna ‘Establecimientos’ se calculan sobre el total de establecimientos únicos, dado que un mismo establecimiento puede aparecer en múltiples cadenas.

Tabla 12: Distribución por *Tipo de Establecimiento*


Tipo de Estab.	Obs. (<i>spells</i>) (%) * / **	Estab. * / **	Prod. * / **	Relación Precios P / NP *	Duración Media (μ)	Q50% Duración (Mediana)	Desviación Estándar (σ)
Supermercado	121.164 (41.25%)	72 (24.91%)	143 (95.33%)	36% / 64%	34.05 (<i>días</i>)	14 (<i>días</i>)	56.30 (<i>días</i>)
Tienda Express	64.441 (21.41%)	76 (26.30%)	96 (64.0%)	36% / 64%	36.95 (<i>días</i>)	14 (<i>días</i>)	63.63 (<i>días</i>)
Farmacia	61.204 (20.33%)	102 (35.29%)	18 (30.0%)	3% / 97%	49.28 (<i>días</i>)	5 (<i>días</i>)	83.48 (<i>días</i>)
Hipermercado	30.022 (9.97%)	14 (4.84%)	42 (77.33%)	43% / 57%	26.63 (<i>días</i>)	9 (<i>días</i>)	52.53 (<i>días</i>)
Minimercado	21.195 (7.04%)	25 (8.85%)	9 (88.0%)	14% / 86%	59.69 (<i>días</i>)	23 (<i>días</i>)	66.73 (<i>días</i>)
Total	301.026 (<i>spells</i>)	289 estab. **	150 prod. **	28% / 72%	38.83 (<i>días</i>)	14 (<i>días</i>)	65.37 (<i>días</i>)


* 'Obs.' = Observaciones | 'Prod.' / 'prod.' = Productos | 'Estab.' ' / 'estab.' = Establecimientos | 'Relación Precios P / NP' = Relación Precios en Promoción y No en Promoción


** Los porcentajes en las columnas 'Observaciones' y 'Productos' indican la proporción del *Tipo de Establecimiento* respecto al total de *spells*. En cambio, los porcentajes en la columna 'Establecimientos' se calculan sobre el total de establecimientos únicos, dado que un mismo establecimiento puede aparecer en múltiples tipos de establecimientos.

Figura 10: Mapa de Calor: Relación entre *Duración*, *Categoría* y *Tipo de Establecimiento*


1. Alimentos









2. Bebidas con Alcohol



3. Bebidas sin Alcohol



4. Cuidado Personal



5. Limpieza




Tabla 13: Distribución por *Municipio*

Día de la semana	Obs. (<i>spells</i>) (%) * / **	Estab. * / **	Prod. * / **	Relación Precios P / NP *	Duración Media (μ)	Q50% Duración (Mediana)	Desviación Estándar (σ)
Municipio CH	76.106 (25.28%)	81 (28.03%)	149 (99.33%)	30% / 70%	36.99 (<i>días</i>)	10 (<i>días</i>)	66.64 (<i>días</i>)
Municipio B	69.422 (23.06%)	70 (24.22%)	150 (100%)	35% / 65%	35.15 (<i>días</i>)	12 (<i>días</i>)	62.85 (<i>días</i>)
Municipio F	39.669 (13.18%)	32 (11.07%)	150 (100%)	42% / 58%	42.17 (<i>días</i>)	19 (<i>días</i>)	63.37 (<i>días</i>)
Municipio E	34.039 (11.31%)	35 (12.11%)	143 (95.33%)	38% / 62%	37.92 (<i>días</i>)	10 (<i>días</i>)	68.66 (<i>días</i>)
Municipio C	27.279 (9.06%)	19 (6.57%)	149 (99.33%)	32% / 68%	32.46 (<i>días</i>)	10 (<i>días</i>)	61.14 (<i>días</i>)
Municipio D	22.472 (7.47%)	21 (7.27%)	150 (100%)	44% / 56%	44.29 (<i>días</i>)	19 (<i>días</i>)	68.43 (<i>días</i>)
Municipio A	16.073 (5.34%)	14 (4.84%)	145 (96.67%)	49% / 51%	49.14 (<i>días</i>)	28 (<i>días</i>)	62.24 (<i>días</i>)
Municipio G	15.966 (5.30%)	17 (5.88%)	149 (99.33%)	50% / 50%	50.15 (<i>días</i>)	27 (<i>días</i>)	67.59 (<i>días</i>)
Total	301.026 (<i>spells</i>)	289 estab. **	150 prod. **	28% / 72%	38.83 (<i>días</i>)	14 (<i>días</i>)	65.37 (<i>días</i>)

* ‘Obs.’ = Observaciones | ‘Prod.’ / ‘prod.’ = Productos | ‘Estab.’ / ‘estab.’ = Establecimientos | ‘Relación Precios P / NP’ = Relación Precios en Promoción y No en Promoción

** Los porcentajes en las columnas ‘Observaciones’ y ‘Productos’ indican la proporción del *Municipio* respecto al total de *spells*. En cambio, los porcentajes en la columna ‘Establecimientos’ se calculan sobre el total de establecimientos únicos, dado que un mismo establecimiento puede aparecer en múltiples municipios.

Figura 11: Media de *Duración* vs Media *Var_Precio_%* (Incrementos) por *Rubro*




Figura 12: Media de *Duración* vs Media *Var_Precio_%* (Reducciones) por *Rubro*



Anexo 5: Resultados modelización con Machine Learning

Resultados **modelización General** (301.026 observaciones):

Tabla 14: Resultados modelización General (*Machine Learning*)

Referencias: ● Mejor resultado | ● Segundo Mejor resultado | ● Tercer Mejor resultado

Modelo	Tipo	MAE	R ²	MSE	RMSE	Características
Decision Tree	Estándar	32.76	0.27	3105.62	55.73	max_depth=10 min_samples_split=10 min_samples_leaf=4 max_features=sqrt ccp_alpha=0.001 min_impurity_decrease=0.0001
Decision Tree	Hiperparametrización	9.89	0.83	716.57	26.77	max_depth=None min_samples_split=2 min_samples_leaf=6 max_features=None ccp_alpha=0.01 min_impurity_decrease=0.02
Extra Trees	Estándar	33.64	0.31	2933.04	54.16	n_estimators=200 max_depth=10 min_samples_split=5 min_samples_leaf=2 max_features=sqrt max_samples=None min_impurity_decrease=0.0 ccp_alpha=0.0 max_leaf_nodes=None
Extra Trees	Hiperparametrización	19.90	0.69	1314.63	36.26	n_estimators=500 max_depth=15 min_samples_split=5 min_samples_leaf=8 max_features=None bootstrap=True max_samples=0.5 min_impurity_decrease=0.0 ccp_alpha=0.001 max_leaf_nodes=None
Random Forest	Estándar	29.95	0.42	2456.72	49.57	n_estimators=200 max_depth=10 min_samples_split=10 min_samples_leaf=4 max_features=sqrt bootstrap=True max_samples=1.0 min_impurity_decrease=0.0 ccp_alpha=0.0 max_leaf_nodes=None
Random Forest	Hiperparametrización	17.72	0.73	1143.70	33.82	n_estimators=500 max_depth=15 min_samples_split=5 min_samples_leaf=8 max_features=None bootstrap=True max_samples=0.5 min_impurity_decrease=0.0 ccp_alpha=0.001 max_leaf_nodes=None

Modelo	Tipo	MAE	R ²	MSE	RMSE	Características
XGBoost	Estándar	22.19	0.64	1505.30	38.80	n_estimators=200 max_depth=6 learning_rate=0.05 subsample=0.7 colsample_bytree=0.7 reg_alpha=0 reg_lambda=1 gamma=0 min_child_weight=5
XGBoost	Hiperparametrización	8.99	0.88	488.33	22.10	n_estimators=300 max_depth=12 learning_rate=0.1 subsample=0.9 colsample_bytree=0.7 reg_alpha=0 reg_lambda=1 gamma=0.1 min_child_weight=3
CatBoost	Estándar	18.59	0.74	1095.61	33.10	iterations=200 depth=10 learning_rate=0.1 l2_leaf_reg=3 border_count=128 subsample=0.8 colsample_bylevel=0.8
CatBoost	Hiperparametrización	12.52	0.85	634.54	25.19	iterations=500 depth=12 learning_rate=0.1 l2_leaf_reg=3 border_count=256 subsample=0.7 colsample_bylevel=0.9
LightGBM	Estándar	19.71	0.72	1177.73	34.32	num_leaves=31 max_depth=-1 learning_rate=0.1 n_estimators=200 min_child_samples=20 subsample=0.8 colsample_bytree=0.8 reg_alpha=0.1 reg_lambda=0.1 boosting_type=gbdt
LightGBM	Hiperparametrización	14.15	0.82	779.79	27.92	num_leaves=60 max_depth=10 learning_rate=0.1 n_estimators=500 min_child_samples=50 subsample=1.0 colsample_bytree=0.7 reg_alpha=0.1 reg_lambda=0.1 boosting_type=gbdt

Comparativa de resultados *Train vs. Test* **modelización General** (301.026 observaciones):

Tabla 15: Comparativa de resultados *Train vs Test* modelización General (*Machine Learning*)

Referencias: ● Mejor resultado | ● Segundo Mejor resultado | ● Tercer Mejor resultado

Modelo	Tipo	MAE Test	MAE Train	R ² Test	R ² Train
Decision Tree	Estándar	32.76	32.83	0.27	0.27
Decision Tree	Hiperparametrización	9.89	7.93	0.83	0.91
Extra Trees	Estándar	33.64	33.66	0.31	0.31
Extra Trees	Hiperparametrización	19.90	19.75	0.69	0.70
Random Forest	Estándar	29.95	29.97	0.42	0.42
Random Forest	Hiperparametrización	17.72	17.40	0.73	0.75
XGBoost	Estándar	22.19	22.08	0.64	0.66
XGBoost	Hiperparametrización	8.99	6.31	0.88	0.96
CatBoost	Estándar	18.59	18.22	0.74	0.76
CatBoost	Hiperparametrización	12.52	11.28	0.85	0.89
LightGBM	Estándar	19.71	19.50	0.72	0.74
LightGBM	Hiperparametrización	14.15	13.32	0.82	0.85

Resultados **modelización rubro Alimentos** (177.196 observaciones – 58.9%):

Tabla 16: Resultados modelización *Machine Learning* (Rubro: Alimentos)

Referencias: ● Mejor resultado | ● Segundo Mejor resultado | ● Tercer Mejor resultado

Modelo	Tipo	MAE	R ²	MSE	RMSE	Características
Decision Tree	Hiperparametrización	8.67	0.78	526.55	22.95	max_depth=None min_samples_split=10 min_samples_leaf=8 max_features=None ccp_alpha=0.0 min_impurity_decrease=0.01
Extra Trees	Hiperparametrización	14.77	0.68	762.94	27.62	n_estimators=500 max_depth=15 min_samples_split=5 min_samples_leaf=8 max_features=None bootstrap=True max_samples=0.5 min_impurity_decrease=0.0 ccp_alpha=0.001 max_leaf_nodes=None
Random Forest	Hiperparametrización	13.00	0.73	644.66	25.39	n_estimators=500 max_depth=15 min_samples_split=5 min_samples_leaf=8 max_features=None bootstrap=True max_samples=0.5 min_impurity_decrease=0.0 ccp_alpha=0.001 max_leaf_nodes=None
XGBoost	Hiperparametrización	8.10	0.88	292.69	17.11	n_estimators=500 max_depth=12 learning_rate=0.05 subsample=0.6 colsample_bytree=0.4 reg_alpha=0.1 reg_lambda=1.5 gamma=0.4 min_child_weight=7
CatBoost	Hiperparametrización	8.64	0.87	298.88	17.29	iterations=500 depth=12 learning_rate=0.1 l2_leaf_reg=3 border_count=256 subsample=0.7 colsample_bylevel=0.9
LightGBM	Hiperparametrización	9.54	0.85	348.99	18.68	num_leaves=60 max_depth=10 learning_rate=0.1 n_estimators=500 min_child_samples=10 subsample=1.0 colsample_bytree=0.7 reg_alpha=0 reg_lambda=0 boosting_type=gbdt

Resultados **modelización rubro *Bebidas con Alcohol*** (14.124 observaciones – 4.7%):

Tabla 17: Resultados modelización *Machine Learning* (Rubro: *Bebidas con Alcohol*)

Referencias: ● Mejor resultado | ● Segundo Mejor resultado | ● Tercer Mejor resultado

Modelo	Tipo	MAE	R ²	MSE	RMSE	Características
Decision Tree	Hiperparametrización	11.50	0.72	627.37	25.05	max_depth=None min_samples_split=15 min_samples_leaf=2 max_features=sqrt ccp_alpha=0.01 min_impurity_decrease=0.02
Extra Trees	Hiperparametrización	16.44	0.66	767.15	27.70	n_estimators=100 max_depth=25 min_samples_split=15 min_samples_leaf=2 max_features=log2 bootstrap=True max_samples=1.0 min_impurity_decrease=0.01 ccp_alpha=0.0 max_leaf_nodes=None
Random Forest	Hiperparametrización	14.30	0.72	621.57	24.93	n_estimators=100 max_depth=25 min_samples_split=15 min_samples_leaf=2 max_features=log2 bootstrap=True max_samples=1.0 min_impurity_decrease=0.01 ccp_alpha=0.0 max_leaf_nodes=None
XGBoost	Hiperparametrización	17.05	0.66	762.44	27.61	n_estimators=200 max_depth=3 learning_rate=0.1 subsample=0.5 colsample_bytree=0.8 reg_alpha=1 reg_lambda=5 gamma=0.2 min_child_weight=10
CatBoost	Hiperparametrización	11.50	0.78	489.22	22.12	iterations=300 depth=12 learning_rate=0.03 l2_leaf_reg=7 border_count=128 subsample=0.9 colsample_bylevel=0.9

Resultados **modelización rubro *Bebidas sin Alcohol*** (23.202 observaciones – 7.7%):

Tabla 18: Resultados modelización *Machine Learning* (Rubro: *Bebidas sin Alcohol*)

Referencias: ● Mejor resultado | ● Segundo Mejor resultado | ● Tercer Mejor resultado

Modelo	Tipo	MAE	R ²	MSE	RMSE	Características
Decision Tree	Hiperparametrización	18.03	0.79	2068.55	45.48	max_depth=15 min_samples_split=2 min_samples_leaf=6 max_features=None ccp_alpha=0.01 min_impurity_decrease=0.05
Extra Trees	Hiperparametrización	19.13	0.72	2746.26	52.40	n_estimators=100 max_depth=25 min_samples_split=15 min_samples_leaf=2 max_features=log2 bootstrap=True max_samples=1.0 min_impurity_decrease=0.01 ccp_alpha=0.0 max_leaf_nodes=None
Random Forest	Hiperparametrización	24.55	0.78	2150.98	46.38	n_estimators=100 max_depth=25 min_samples_split=15 min_samples_leaf=2 max_features=log2 bootstrap=True max_samples=1.0 min_impurity_decrease=0.01 ccp_alpha=0.0 max_leaf_nodes=None
XGBoost	Hiperparametrización	33.49	0.69	2996.35	54.74	n_estimators=200 max_depth=3 learning_rate=0.1 subsample=0.5 colsample_bytree=0.8 reg_alpha=1 reg_lambda=5 gamma=0.2 min_child_weight=10
CatBoost	Hiperparametrización	21.29	0.83	1631.35	40.39	iterations=300 depth=12 learning_rate=0.03 l2_leaf_reg=7 border_count=128 subsample=0.9 colsample_bylevel=0.9
LightGBM	Hiperparametrización	14.79	0.86	1332.23	36.5	num_leaves=60 max_depth=20 learning_rate=0.1 n_estimators=500 min_child_samples=50 subsample=0.7 colsample_bytree=0.7 reg_alpha=1 reg_lambda=1 boosting_type=gbdt

Resultados **modelización rubro *Cuidado Personal*** (77.629 observaciones – 25.8%):

Tabla 19: Resultados modelización *Machine Learning* (Rubro: *Cuidado Personal*)

Referencias: ● Mejor resultado | ● Segundo Mejor resultado | ● Tercer Mejor resultado

Modelo	Tipo	MAE	R ²	MSE	RMSE	Características
Decision Tree	Hiperparametrización	6.76	0.90	657.80	25.65	max_depth=None min_samples_split=25 min_samples_leaf=6 max_features=None ccp_alpha=0.01 min_impurity_decrease=0.02
Extra Trees	Hiperparametrización	18.62	0.85	1041.89	32.28	n_estimators=600 max_depth=None min_samples_split=2 min_samples_leaf=1 max_features=log2 bootstrap=True max_samples=0.75 min_impurity_decrease=0.02 ccp_alpha=0.001 max_leaf_nodes=None
Random Forest	Hiperparametrización	14.27	0.89	769.30	27.74	n_estimators=600 max_depth=None min_samples_split=2 min_samples_leaf=1 max_features=log2 bootstrap=True max_samples=0.75 min_impurity_decrease=0.02 ccp_alpha=0.001 max_leaf_nodes=None
XGBoost	Hiperparametrización	8.00	0.93	506.52	22.51	n_estimators=500 max_depth=12 learning_rate=0.05 subsample=0.6 colsample_bytree=0.4 reg_alpha=0.1 reg_lambda=1.5 gamma=0.4 min_child_weight=7
CatBoost	Hiperparametrización	7.92	0.93	486.36	22.05	iterations=500 depth=12 learning_rate=0.1 l2_leaf_reg=3 border_count=256 subsample=0.7 colsample_bylevel=0.9
LightGBM	Hiperparametrización	8.57	0.92	570.65	23.89	num_leaves=60 max_depth=20 learning_rate=0.1 n_estimators=500 min_child_samples=50 subsample=0.7 colsample_bytree=0.7 reg_alpha=1 reg_lambda=1 boosting_type=gbdt

Resultados **modelización rubro Limpieza** (8.875 observaciones – 2.9%):

Tabla 20: Resultados modelización *Machine Learning* (Rubro: Limpieza)

Referencias: ● Mejor resultado | ● Segundo Mejor resultado | ● Tercer Mejor resultado

Modelo	Tipo	MAE	R ²	MSE	RMSE	Características
Decision Tree	Hiperparametrización	19.25	0.70	1368.60	36.99	max_depth=15 min_samples_split=2 min_samples_leaf=6 max_features=None ccp_alpha=0.01 min_impurity_decrease=0.05
Extra Trees	Hiperparametrización	25.21	0.67	1469.50	38.33	n_estimators=100 max_depth=25 min_samples_split=15 min_samples_leaf=2 max_features=log2 bootstrap=True max_samples=1.0 min_impurity_decrease=0.01 ccp_alpha=0.0 max_leaf_nodes=None
Random Forest	Hiperparametrización	22.26	0.72	1259.58	35.49	n_estimators=100 max_depth=25 min_samples_split=15 min_samples_leaf=2 max_features=log2 bootstrap=True max_samples=1.0 min_impurity_decrease=0.01 ccp_alpha=0.0 max_leaf_nodes=None
XGBoost	Hiperparametrización	25.61	0.68	1439.69	37.94	n_estimators=200 max_depth=3 learning_rate=0.1 subsample=0.5 colsample_bytree=0.8 reg_alpha= reg_lambda=5 gamma=0.2 min_child_weight=10
CatBoost	Hiperparametrización	18.87	0.77	1024.03	32.00	iterations=300 depth=8 learning_rate=0.05 l2_leaf_reg=3 border_count=256 subsample=1.0 colsample_bylevel=0.8

Anexo 6: Resultados modelización con Survival Machine Learning

Resultados **modelización General** (352.274 observaciones):

Tabla 21: Resultados modelización General (*Survival Machine Learning*)

Referencias: ● Mejor resultado ● Segundo Mejor resultado			
Modelo	C-Index	MAE	Características
Random Survival Forest	0.729	33.10	n_estimators=1200 min_samples_split=6 min_samples_leaf=8 max_features=Sqrt max_depth=10
Cox Proportional Hazards	0.707	40.60	alpha_min_ratio=0.001 L1_ratio=0.9

*MAE calculado desconsiderando *spells* censurados por medio de la librería *SurvivalEVAL* (Qi et al., 2024)

Comparativa de resultados *Train vs. Test* **modelización General** (352.274 observaciones):

Tabla 22: Comparativa de resultados *Train vs Test* modelización General (*Survival Machine Learning*)

Referencias: ● Mejor resultado ● Segundo Mejor resultado				
Modelo	C-Index Train	C-Index Test	MAE Train *	MAE Test *
Random Survival Forest	0.729	0.731	33.10	32.71
Cox Proportional Hazards	0.707	0.729	40.60	40.47

*MAE calculado desconsiderando *spells* censurados por medio de la librería *SurvivalEVAL* (Qi et al., 2024)

Resultados modelización por Rubro:

Tabla 23: Resultados modelización *Survival Machine Learning* por Rubro

Referencias: ● Mejor resultado | ● Segundo Mejor resultado

Modelo	Rubro	Observaciones	C-Index	MAE *	Características
Random Survival Forest	Alimentos	204.395 (58.0%)	0.731	26.73	n_estimators=500 min_samples_split=12 min_samples_leaf=25 max_features=log2 max_depth=12
Cox Proportional Hazards	Alimentos	204.395 (58.0%)	0.653	33.35	alpha_min_ratio=0.001 L1_ratio=0.1
Random Survival Forest	Bebidas con Alcohol	16.540 (4.7%)	0.732	23.11	n_estimators=900 min_samples_split=8 min_samples_leaf=18 max_features=log2 max_depth=None
Cox Proportional Hazards	Bebidas con Alcohol	16.540 (4.7%)	0.696	36.44	alpha_min_ratio=0.001 L1_ratio=0.5
Random Survival Forest	Bebidas sin Alcohol	28.572 (8.1%)	0.735	32.69	n_estimators=700 min_samples_split=10 min_samples_leaf=20 max_features=log2 max_depth=None
Cox Proportional Hazards	Bebidas sin Alcohol	28.572 (8.1%)	0.672	62.17	alpha_min_ratio=0.001 L1_ratio=0.5
Random Survival Forest	Cuidado Personal	92.111 (26.2%)	0.782	19.31	n_estimators=750 min_samples_split=10 min_samples_leaf=20 max_features=log2 max_depth=15
Cox Proportional Hazards	Cuidado Personal	92.111 (26.2%)	0.664	50.79	alpha_min_ratio=0.001 L1_ratio=0.1
Random Survival Forest	Limpieza	10.656 (3.0%)	0.739	26.17	n_estimators=800 min_samples_split=8 min_samples_leaf=20 max_features=log2 max_depth=None
Cox Proportional Hazards	Limpieza	10.656 (3.0%)	0.717	52.64	alpha_min_ratio=0.001 L1_ratio=0.5

*MAE calculado desconsiderando *spells* censurados por medio de la librería *SurvivalEVAL* (Qi et al., 2024)

Anexo 7: Base de Datos y Código Desarrollado

Los *Scripts* o códigos utilizados, así como las bases de datos empleadas en este trabajo se encuentran disponibles públicamente en los repositorios de GitHub de los autores. Quienes tengan interés en acceder a los mismos pueden hacerlo por medio de los siguientes enlaces:

Repositorio Paolo Pinotti:

https://github.com/PaoloPPA23/ML_applied_to_price_duration/tree/main

Repositorio Martín Rey:

https://github.com/martinrey98/ML_applied_to_price_duration/tree/main

La estructura general del código desarrollado se compone de 5 *Notebooks*; cada uno de ellos con una finalidad distinta y definida según se detalla a continuación:

- [1] **Notebook 1:** Consolidación base de precios (Enero 2021 – Junio 2024).
- [2] **Notebook 2:** Generación de base de *Price Spells* (Enero 2021 – Junio 2024).
- [3] **Notebook 3:** Análisis Estadístico base *Price Spell*.
- [4] **Notebook 4:** Modelización Tradicional de *Machine Learning: Decision Tree, Extra Trees, Random Forest, XGBoost, CatBoost, LightGBM*.
- [5] **Notebook 5:** Modelización *Survival Machine Learning: Cox Proportional Hazards, Random Survival Forest (RSF)*.

Bibliografia

- [1] Alanis, E., Chava, S., & Shah, A. (2022). *Benchmarking machine learning models to predict corporate bankruptcy* (Working Paper No. 4249412). SSRN. https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4249412
- [2] Alexandre, L., Pegios, K., Kotsakis, E., & Clarke, D. (2020). Price forecasting for the balancing energy market using machine-learning regression. *Energies*, 13(20), 5420. <https://doi.org/10.3390/en13205420>
- [3] Araujo, G. S., & Gaglianone, W. P. (2023). Machine learning methods for inflation forecasting in Brazil: New contenders versus classical models. *Latin American Journal of Central Banking*, 4(2), 100087. <https://doi.org/10.1016/j.latchb.2023.100087>
- [4] Aucremanne, L., & Dhyne, E. (2004). *How frequently do prices change? Evidence based on the micro data underlying the Belgian CPI* (Working Paper Research No. 44). National Bank of Belgium. <https://ideas.repec.org/p/nbb/reswpp/200404-1.html>
- [5] Bai, M., Zheng, Y., & Shen, Y. (2022). Gradient boosting survival tree with applications in credit scoring. *Journal of the Operational Research Society*, 73(1), 39-55. <https://doi.org/10.1080/01605682.2021.1919035>
- [6] Bodoh-Creed, B., Boehnke, P., & Hickman, B. (2018). Using machine learning to predict price dispersion. *Journal of Marketing Research*, 55(1), 86-98. <https://doi.org/10.1177/0022243717740939>

- [7] Bone-Winkel, G. F., & Reichenbach, F. (2024). Improving credit risk assessment in P2P lending with explainable machine learning survival analysis. *Digital Finance*, 6(3), 501-542. <https://doi.org/10.1007/s42521-024-00114-7>
- [8] Borraz, F., & Zipitria, L. (2013). Fijación de precios minoristas: El caso de Uruguay. En *Dinámica inflacionaria, persistencia y formación de precios y salarios* (pp. 209-348). CINVE. <https://EconPapers.repec.org/RePEc:cml:incocp:2sp-9>
- [9] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32. <https://doi.org/10.1023/A:1010933404324>
- [10] Calainho, F. D., Minne, A. M., & Francke, M. K. (2024). A machine learning approach to price indices: Applications in commercial real estate. *The Journal of Real Estate Finance and Economics*, 68(4), 624-653. <https://doi.org/10.1007/s11146-022-09893-7>
- [11] Cavallo, A. (2015). *Scraped data and sticky prices* (NBER Working Paper No. 21490). National Bureau of Economic Research. <https://doi.org/10.3386/w21490>
- [12] Chen, T., & Guestrin, C. (2016, agosto 13). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16)*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- [13] Correa, A. da S., Petrassi, M. B. S., & Santos, R. (2016). *Price-setting behavior in Brazil: Survey evidence* (Working Paper No. 422). Central Bank of Brazil. <https://ideas.repec.org/p/bcb/wpaper/422.html>
- [14] Cox, D. R. (1972). Regression models and life tables (with discussion). *Journal of the Royal Statistical Society: Series B (Methodological)*, 34(2), 187-220. <https://doi.org/10.1111/j.2517-6161.1972.tb00899.x>

- [15] Dotsey, M., King, R. G., & Wolman, A. L. (1999). State-dependent pricing and the general equilibrium dynamics of money and output. *The Quarterly Journal of Economics*, 114(2), 655-690.
<https://ideas.repec.org/a/oup/qjecon/v114y1999i2p655-690.html>
- [16] Ellis, C. (2009). *Do supermarket prices change from week to week?* (Bank of England Working Paper No. 378). Bank of England.
<https://ideas.repec.org/p/boe/boeewp/0378.html>
- [17] Freund, Y., & Schapire, R. E. (1997). A decision-theoretic generalization of on-line learning and an application to boosting. *Journal of Computer and System Sciences*, 55(1), 119-139. <https://doi.org/10.1006/jcss.1997.1504>
- [18] Geurts, P., Ernst, D., & Wehenkel, L. (2006). Extremely randomized trees. *Machine Learning*, 63(1), 3-42. <https://doi.org/10.1007/s10994-006-6226-1>
- [19] Ho, W. K. O., Tang, B.-S., & Wong, S. W. (2021). Predicting property prices with machine learning algorithms. *Journal of Property Research*, 38(1), 48-70.
<https://doi.org/10.1080/09599916.2020.1832558>
- [20] Instituto Nacional de Estadística [INE]. (2022, diciembre 1). *Metodología índice de precios del consumo*.
<https://www5.ine.gub.uy/documents/Estad%C3%ADsticasecon%C3%B3micas/PDF/IPC/2022/Metodolog%C3%ADa%20IPC%202022.pdf>
- [21] Ishwaran, H., Kogalur, U. B., Blackstone, E. H., & Lauer, M. S. (2008). Random survival forests. *The Annals of Applied Statistics*, 2(3), 841-860.
<https://doi.org/10.1214/08-AOAS169>

- [22] James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An introduction to statistical learning: With applications in Python*. Springer International Publishing.
- [23] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30. https://proceedings.neurips.cc/paper_files/paper/2017/file/6449f44a102fde848669bdd9eb6b76fa-Paper.pdf
- [24] Klenow, P. J., & Kryvtsov, O. (2008). State-Dependent or Time-Dependent Pricing: Does it Matter for Recent U.S. Inflation? *The Quarterly Journal of Economics*, 123(3), 863-904. <https://doi.org/10.1162/qjec.2008.123.3.863>
- [25] Kochen, F. (2016). *Price-setting in Mexico and the real effects of monetary shocks* (Working Paper No. 21). Banco de México. <https://ideas.repec.org/p/bdm/wpaper/2016-21.html>
- [26] Li, L.-W., Liu, X., Meng-Lu, S., Zhao, M.-J., & Liu, H. (2024). Development and validation of a random survival forest model for predicting long-term survival of early-stage young breast cancer patients based on the SEER database and an external validation cohort. *American Journal of Cancer Research*, 14, 1609-1621. <https://doi.org/10.62347/OJTY4008>
- [27] Li, R., & Belford, G. (2002). Instability of decision tree classification algorithms. *Proceedings of the eighth ACM SIGKDD international conference on knowledge discovery and data mining*, 570-575. <https://doi.org/10.1145/775047.775131>

- [28] Medeiros, M. C., Vasconcelos, G. F. R., Veiga, Á., & Zilberman, E. (2021). Forecasting inflation in a data-rich environment: The benefits of machine learning methods. *Journal of Business & Economic Statistics*, 39(1), 98-119. <https://doi.org/10.1080/07350015.2019.163>
- [29] Micci-Barreca, D. (2001). A preprocessing scheme for high-cardinality categorical attributes in classification and prediction problems. *SIGKDD Explorations*, 3, 27-32. <https://doi.org/10.1145/507533.507538>
- [30] Nakamura, E., & Steinsson, J. (2008). Five facts about prices: A reevaluation of menu cost models. *The Quarterly Journal of Economics*, 123(4), 1415-1464. <https://doi.org/10.1162/qjec.2008.123.4.1415>
- [31] Peña, J., & Prades, E. (2021). *Price setting in Chile: Micro evidence from consumer on-line prices during the social outbreak and Covid-19* (No. 2112). Banco de España. <https://ideas.repec.org/p/bde/wpaper/2112.html>
- [32] Probst, P., & Boulesteix, A.-L. (2018). To tune or not to tune the number of trees in random forest? *Journal of Machine Learning Research*, 18, 1-18. <https://doi.org/10.48550/arXiv.1705.05654>
- [33] Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. En S. Bengio, H. Wallach, H. Larochelle, K. Grauman, N. Cesa-Bianchi, & R. Garnett (Eds.), *Advances in Neural Information Processing Systems* (Vol. 31). Curran Associates, Inc. https://proceedings.neurips.cc/paper_files/paper/2018/file/14491b756b3a51daac41c24863285549-Paper.pdf

- [34] Qi, S., Kumar, N., Farrokh, M., Sun, W., Kuan, L.-H., Ranganath, R., Henao, R., & Greiner, R. (2023). *An Effective Meaningful Way to Evaluate Survival Models*. <https://doi.org/10.48550/arXiv.2306.01196>
- [35] Qi, S., Sun, W., & Greiner, R. (2024). SurvivalEVAL: A comprehensive open-source Python package for evaluating individual survival distributions. *Proceedings of the AAAI Symposium Series*, 2, 453-457. <https://doi.org/10.1609/aaais.v2i1.27713>
- [36] Quinlan, J. R. (1986). Induction of decision trees. *Machine Learning*, 1(1), 81-106. <https://doi.org/10.1007/BF00116251>
- [37] Rahman, S., Maynard, N., Trudgill, N., Crosby, T., Park, M., Wahedally, H., Underwood, T., & Cromwell, D. (2021). AUGIS Surv-G: Prediction of long-term survival after gastrectomy using random survival forests. *British Journal of Surgery*, 108. <https://doi.org/10.1093/bjs/znab237>
- [38] Regueira, C. (2020). *Estrategias de precio de los supermercados en Uruguay* (No. 0620). <https://EconPapers.repec.org/RePEc:ude:wpaper:0620>
- [39] Rodríguez-Vargas, A. (2020). Forecasting Costa Rican inflation with machine learning methods. *Latin American Journal of Central Banking*, 1(1), 100012. <https://doi.org/10.1016/j.latchb.2020.100012>
- [40] Romero, Z. (2021). *Pronósticos de inflación con métodos de aprendizaje automático* [Universidad de la República, Facultad de Ciencias Sociales]. <https://www.colibri.udelar.edu.uy/jspui/handle/20.500.12008/44870>
- [41] Royston, P., & Altman, D. G. (2013). External validation of a Cox prognostic model: Principles and methods. *BMC Medical Research Methodology*, 13(1), 13. <https://doi.org/10.1186/1471-2288-13-33>

- [42] Saha, P., Marouf, Y., Pozzebon, H., Guergachi, A., Keshavjee, K., Noaeen, M., & Shakeri, Z. (2024). *Predicting time to diabetes diagnosis using random survival forests* (Preprint).
- [43] Solórzano, D., & Arango-Castillo, L. (2024). Price duration using daily online data: Time-or state-dependent? *Latin American Journal of Central Banking*, 100138. <https://doi.org/10.1016/j.lacsb.2024.100138>
- [44] Song, K., Song, J., Chen, F., Lin, K., Ma, X., & Jiang, J. (2018). Prognostic nomograms for predicting overall and cancer-specific survival of high-grade osteosarcoma patients. *Journal of Bone Oncology*, 13, 110. <https://doi.org/10.1016/j.jbo.2018.09.012>
- [45] van der Wal, C. (2024). *Predicting future recoveries of defaulted loans: A random survival forest approach* [Master's thesis, Erasmus University Rotterdam]. <https://hdl.handle.net/2105/12345>
- [46] VanderPlas, J. (2016). *Python Data Science Handbook*. O'Reilly Media. <https://jakevdp.github.io/PythonDataScienceHandbook/>
- [47] Veena, K., Chaturvedi, A., & Gupta, C. P. (2017). Amazon EC2 spot price prediction using regression random forests. *IEEE Transactions on Cloud Computing*, 1, 59-72. <https://doi.org/10.1109/TCC.2017.2780159>
- [48] Vermeulen, P., Dias, D. A., Dossche, M., Gautier, E., Hernando, I., Sabbatini, R., & Stahl, H. (2012). Price setting in the euro area: Some stylized facts from individual producer price data. *Journal of Money, Credit and Banking*, 44(8), 1631-1650. <https://doi.org/10.1111/j.1538-4616.2012.00547.x>
- [49] Walsh, C. E. (2017). *Monetary Theory and Policy*. MIT Press.

- [50] Wang, Z., Jiang, C., Ding, Y., Lyu, X., & Liu, Y. (2018). A Novel behavioral scoring model for estimating probability of default over time in peer-to-peer lending. *Electronic Commerce Research and Applications*, 27, 74-82. <https://doi.org/10.1016/j.elerap.2017.12.006>
- [51] Zipitría, L., & Rius, A. (2016). *Formación y determinación de precios en el Uruguay* (No. 39864). Naciones Unidas Comisión Económica para América Latina y el Caribe (CEPAL). <https://ideas.repec.org/p/ecr/col032/39864.html>